

大语言模型在中医领域的标准化评估

曹露, 许林, 张宇洁, 张林帅, 付亚琴, 蒋涛

(成都中医药大学智能医学学院, 四川 成都 611100)

摘要: 目的 针对目前大语言模型(LLMs)在中医学领域测评中的空缺,设计并构建一个中医学测评基准数据集,以对LLMs在中医学知识的掌握与推理表现进行全面、客观地评测,从而为LLMs在中医领域的性能优化提供科学、可靠的依据。方法 从中医标准化考试和教科书中收集数据,构建了一个涵盖13个学科共29 506道题的中医测评基准数据集。实验共选取了3个通用模型(GPT3.5、ChatGLM3、Baichuan)和5个中文医疗模型(PULSE、BenTsao、HuatuoGPT2、BianQue2、ShenNong),对它们在答案预测能力和答案推理能力进行全面评测。测评结果使用准确率、F1值、BLEU、Rouge等指标进行量化评估。结果 答案预测实验的结果显示,Baichuan在单项选择题中准确率最高,为36.07%;ChatGLM3在多项选择题中准确率和F1值最高,为18.96%和76.31%。答案推理实验的结果显示,Baichuan在BLEU-1分值最高,为24.71;ChatGLM3在Rouge-1分值最高,为44.64。结论 通用LLMs整体表现略优于中文医疗LLMs,同时所有模型在选择题上的准确率都未超过60%,反映出LLM在中医领域中仍面临巨大的挑战和提升空间。

关键词: 大语言模型;中文医疗模型;测评基准;ChatGPT;中医学

中图分类号:R2-03

文献标志码:A

文章编号:1672-0482(2024)12-1383-10

DOI:10.14148/j.issn.1672-0482.2024.1383

引文格式:曹露,许林,张宇洁,等.大语言模型在中医领域的标准化评估[J].南京中医药大学学报,2024,40(12):1383-1392.

Standardized Evaluation of Large Language Models in Traditional Chinese Medicine

CAO Lu, XU Lin, ZHANG Yujie, ZHANG Linshuai, FU Yaqin, JIANG Tao

(School of Intelligent Medicine, Chengdu University of Traditional Chinese Medicine, Chengdu 611100, China)

ABSTRACT: OBJECTIVE Aiming at the current vacancy of large language models (LLMs) in TCM evaluation, a TCM benchmark dataset is designed and constructed to comprehensively and objectively evaluate the mastery and reasoning performance of LLMs in TCM knowledge, providing scientific and reliable basis for optimizing the performance of LLMs in the field of TCM. **METHODS** This benchmark includes 29 506 questions across 13 subjects, with data collected from standardized TCM exams and textbooks. Three general-purpose models (GPT-3.5, ChatGLM3, Baichuan) and five Chinese medical models (PULSE, BenTsao, HuatuoGPT2, BianQue2, ShenNong) were evaluated with answer prediction and answer reasoning tasks. The evaluation results were quantitatively assessed using metrics including accuracy, F1 score, BLEU, and Rouge. **RESULTS** For the answer prediction task, Baichuan had the highest accuracy of 36.07% in single-choice questions, while ChatGLM3 achieved the highest accuracy of 18.96% and F1 score of 76.31% in multiple-choice questions. For the answer reasoning experiment, Baichuan scored highest on BLEU-1 with 24.71, while ChatGLM3 achieved the highest Rouge-1 score of 44.64. **CONCLUSION** In this study, general LLMs performed slightly better than Chinese medical LLMs. Meanwhile, all models' accuracy on choice questions remained below 60%, reflecting the significant challenges and room for improvement that LLMs still face in the field of TCM.

KEYWORDS: large language models; Chinese medical models; evaluation benchmark; ChatGPT; traditional Chinese medicine

大语言模型(LLMs)是具有庞大参数的深度学习模型,它们通过无监督学习方式在大量文本数据上进行训练而来^[1]。LLMs在自然语言处理领域的任务上展现了强大的能力,包括自然语言理解、生成、专业领域任务和推理等方面^[2]。自ChatGPT^[3]发布以来,LLMs已广泛为人所知,并在医疗健康领

域应用迅速发展。LLMs不仅可以辅助临床决策,而且能为复杂的医疗问题提供创新解决方案^[4]。LLMs分为通用领域模型和微调模型,具有代表性的通用LLMs包括ChatGPT^[5]、Claude^[6]、ChatGLM^[7]等。微调模型是指在预训练的基础上,通过在特定任务的数据集上进行额外的调优,以提升其在该任

收稿日期:2024-06-25

基金项目:四川省科技厅科技计划项目(2024NSFC0722,2024YFHZ0320);四川省中医药管理局重大项目(2024zd030);河南省科技攻关项目(242102210100);自贡市第一人民医院高质量发展重点研发科技计划项目(2024CZL02)

第一作者:曹露,女,硕士研究生,E-mail:caolu@stu.cdutcm.edu.cn

通信作者:蒋涛,男,教授,主要从事人工智能研究,E-mail:jiangtop@cdutcm.edu.cn;

许林,男,副教授,主要从事自然语言处理研究,E-mail:xulin@cdutcm.edu.cn

务上的性能表现。为使 LLMs 更好地适应医疗任务,近期一些研究热点是对公开可用的通用 LLMs (如 LLaMA^[8]、ChatGLM^[9]和 Bloom^[10]等)进行指令微调,以开发中文医疗 LLMs。目前具有代表性的中文医疗 LLMs 包括 HuatuoGPT^[11]、BenTsao^[12]、Zhongjing^[13]等。医疗 LLMs 可以增强医学知识理解、提高诊断准确性、实现个性化治疗建议等^[14]。

随着医疗 LLMs 的快速发展,一个标准化的医学测评基准显得愈发重要,它不仅能为医疗领域的 LLMs 提供可靠和权威的评估结果,还是有效开发和应用这些模型的关键。当前,各种医疗基准已经根据不同地区和医疗体系进行了量身定制,这些基准对评估 LLMs 的性能方面具有重要意义。现有的医学测评基准包括开放式问答和选择题,例如 WebMedQA^[15]的问答题直接由患者的问题和医生的答案构建,虽然真实但在评估医学领域深度知识时存在局限性,难以全面反映复杂的临床实践情况。相比之下,有标准答案的选择题能够提供更加客观的评价结果。使用有标准答案选择题的基准包括:从美国医学执业资格考试中收集的 MedQA^[16]、从印度医学入学考试中收集的 MedMCQA^[17]、侧重中国生物医学信息的评估的 CBLUE^[18]和 PromptCBLUE^[19]、包含七个数据集的大型医学测评基准 MultiMedQA^[20]。尽管以上基准在西医学领域已经相当成熟度,但缺乏中医方面的内容。中医,作为中国传统医学的瑰宝,其理论和实践体系与西医存在显著差异。因此,现有的西医基准并不能充分展现 LLMs 在中医领域的实际表现。虽然已有如 CMExam^[21]、CMB^[22]和 MedBench^[23]等使用选择题的中文医疗基准,但它们仍主要侧重于西医知识,且问答多为对选择题答案的解析,缺乏客观性。此外,这些基准对中医内容的覆盖面极为有限,无法全面评估 LLMs 在中医各个领域的实际性能。

因此,目前学术界缺乏一个综合性的中医领域评估基准,以便更全面、更准确地考量 LLMs 在中医领域的表现水平。在现有中医学 LLMs 的评估中,ZhongJing-TCM^[13]和 QiZhenGPT^[24]均是采用了医生的主观评价,但手工评估耗时耗力,难以大规模推广且存在一定的主观性。HuatuoGPT-II^[25]为避免基准提前泄露于 LLMs,使用 2023 年中国国家药师执照考试题进行评估,但内容覆盖范围有局限性,无法全面反映模型在中医各个领域的性能。因此,迫切需要开发适应中医诊疗的客观且系统化的 LLMs

测评基准,以弥补该领域评价标准的空白,更好地推动中医领域 LLMs 的发展和应用。

故本研究首先充分结合中医标准化考试和教材的内容,构建了一个涵盖多学科、多题型的中医学测评基准数据集。然后共选取了 3 个通用模型和 5 个中文医疗模型,对它们在答案预测能力和答案推理能力进行全面测评。最后使用准确率 (Accuracy)、F1 值、BLEU (Bilingual Evaluation Understudy) 和 Rouge (Recall-Oriented Understudy for Gisting Evaluation) 等指标对结果进行评分。在本研究测评的 8 个模型中,通用模型 ChatGLM3 和 Baichuan 在中医领域相关任务上的整体表现综合性能最优。

1 测评基准数据集

本研究首先构建了一份包含答案预测题与答案推理题这两种题型的中医学测评基准数据集。其中,答案预测题包括单项选择题和多项选择题,每题最多有 5 个候选答案,用于评估模型预测答案的正确率。答案推理题用于评估模型的推理能力,从而全面评估模型在中医学领域的知识掌握和推理能力。同时,为了确保测评的全面性和专业性,本研究将所有题依据学科进行分类,包括中医基础理论、中医诊断、中药学、方剂学、针灸学、中医内科学、中医外科学、中医妇科学、中医儿科学、中医经典、卫生法规、医学伦理、医学人文共 13 个学科。通过 LLMs 对这些问题的回答,可以深入理解 LLMs 在中医药理论和实践上的能力,为相关领域的研究提供有力支撑。

1.1 答案预测题

答案预测题收集自两种标准化中医考试:中国国家中医执业医师资格考试和中国国家中医研究生入学考试真题,共计 29 506 道题。其中,中医执业医师考试从 2007 年至 2022 年共 29 231 道题,删除重复的题 4 439 道后剩余 24 792 道单选题;中医研究生考试从 1991 年至 2019 年共 4 714 道题,其中单选题 3 365 道,多选题 1 349 道。两种考试中的共用选项和共用题干的题型均被更改为单独的单项选择题以便模型回答。从学科分布上看,如图 1A 所示,中医内科学题目占比最大,为 18.26% (5 388 道题);法规、伦理和人文这三科题目最少,合计占比仅为 4.65% (1 372 道题)。

1.2 答案推理题

为了确保数据的准确性,所有答案推理题的题目和答案均从高等中医院校规划第十版教材中整理而来。本研究选取了《中医基础理论》《中医诊断

学》《中药学》《方剂学》《针灸学》和《中医内科学》这6本书中常考的重点内容,共构建了1691道问答题及其正确答案。这些题目内容涵盖广泛,可充分反映LLMs在中医领域知识的掌握能力。具体问题包括中医学概念、证型的表现、中药的功效主治、

方剂的组成和功效主治、疾病的概念、症状和病因病机和腧穴的定位和主治疾病。从图1B学科分布上看,方剂学题目占比最大,为27.32%(462道题);内科学题目占比最小,为6.39%(108道题)。答案推理题的数据示例如表1所示。




图1 测评基准数据集学科分布
Fig.1 Subject distribution of benchmark datasets

表1 答案推理题示例

Table 1 Example of answer reasoning question


学科	概念	问题	参考答案
中医基础理论	五行木	特性	“木曰曲直”:曲,屈也,弯曲;直,伸也,伸直。曲直,指树木枝条具有生长、升发、柔和、能屈能伸的特性。引申为凡具有生长、升发、条达、舒畅等类似性质或作用的事物和现象,归属于木。
中医诊断学	气虚证	证候表现	神疲乏力,少气懒言,气短,头晕目眩,自汗,动则诸症加剧,舌质淡嫩,脉虚。
中药学	麻黄	功效和主治	麻黄发汗解表,宣肺平喘,利水消肿。主治风寒感冒(表实无汗);咳嗽气喘;风水水肿。
方剂学	麻黄汤	功效和主治	麻黄汤发汗解表,宣肺平喘,主治外感风寒表实证,症状是恶寒发热,无汗而喘,脉浮紧。
	麻黄汤	组成	麻黄、甘草、桂枝、杏仁
中医内科学	感冒	概念和临床表现	感冒是以鼻塞、流涕、喷嚏、头痛、恶寒、发热、全身不适为主症的病症,是最常见的外感病之一。
	感冒	病因病机	感冒是因六淫、时行之邪,侵袭肺卫,以致卫表不和,肺失宣肃而为病。
针灸学	中府	经络、定位及主治	中府属于手太阴肺经,定位是在胸部,横平第1肋间隙,锁骨下窝外侧,前正中线旁开6寸。主治咳嗽、气喘、胸痛等胸肺病证;肩背痛。

2 方法

2.1 实验设计

在自建完中医测评基准数据集后,本研究针对不同题型设计了相应的提示格式,引导模型推理生成答案。然后,本研究共选取了8个模型,包括3个通用模型(GPT3.5、ChatGLM3、Baichuan)和5个中

文医疗模型(PULSE、BenTsao、HuatuogPT2、BianQue2、ShenNong),对它们在答案预测能力和答案推理能力进行全面测评。最后,实验研究使用准确率、F1值、BLEU和Rouge等指标对结果进行评比。具体实验流程图如图2所示。



注：A. 答案预测题中学科分布；B. 答案推理题中学科分布

图 2 实验流程图

Fig. 2 Experimental flow chart

2.2 模型选择

为全面评估不同参数规模和领域的 LLMs,本研究选取了一系列通用领域和中文医疗领域的 LLMs 进行比较,并以 GPT3.5 作为基线模型。

3 个通用领域的 LLMs 分别是: GPT3.5: 由 OpenAI 使用人类反馈强化学习训练的一个具有重大影响力的模型。ChatGLM3: 由智谱 AI 和清华大学 KEG 实验室基于 GLM (General Language Model) 架构训练的对话预训练模型。Baichuan^[26]: 由百川智能基于 Transformer 结构,在大约 1.2 万亿令牌 (tokens) 上训练开发的开源可商用的大规模语言模型。

5 个中文医疗 LLMs 分别是: PULS^[27]: 基于约 40 万个中文医学领域和通用领域的指令微调数据以 bloomz-7b1-mt 或 InternLM-20B 作为基础模型微调而得。BenTsao: 从 CMeKG 医学知识图谱和医学文献摘要^[28] 收集专业知识,并利用 GPT3.5 接口围绕这些数据构建多轮问答指令微调数据集,基于该数据集以 LLaMA、Bloom、Alpaca-Chinese 和 Chinese-Mixtral-8x7B 等作为基础模型进行指令微调而得。BianQue2^[29]: 结合当前开源的中文医疗问答数据集和自建的生活空间健康对话大数据构建的扁鹊健康大数据 BianQueCorpus, 基于该数据集以 ChatGLM-6B 作为基础模型,最后经过全量参数的

指令微调训练而得。HuatuoGPT2: 利用真实世界的医疗问题作为指令,并借助 GPT4 生成相应的回应作为微调数据,从而构建出适应医疗环境 Huatuo-26M^[30] 数据集,基于该数据集以 Baichuan2-7B-Base 和 Yi-34B 为基础模型微调得到。ShenNong^[31]: 以开源的中医药知识图谱为基础,采用以实体为中心的自指令方法,调用 ChatGPT 得到 2.6 万中医药指令数据集 ChatMed-TCM-Dataset,基于该数据集以 LLaMA 为基础模型,采用 LoRA 微调得到。LLMs 的具体信息如表 2 所示。

在研究中发现,中文医疗 LLMs 的精确指令遵循能力较差,即模型无法根据输入要求精确输出。例如 BenTsao 在答案推理实验中会生成大量重复片段内容,而 HuatuoGPT2、BianQue2 和 ShenNong 在答案预测实验中常常无法根据预设的提示返回正确答案。举例在单项选择题中模型会返回多个选项作为答案,或者进行解释却没有选择正确答案选项,甚至直接生成诸如“很抱歉,我无法回答您的问题,建议您咨询医生或中医师,以获取更加准确的答案。”之类的回应。鉴于上述现象,本研究决定不使用这些模型进行相关的实验评估,即答案推理实验中排除 BenTsao,答案预测实验中不采用 HuatuoGPT2、BianQue2 和 ShenNong。尽管这增加了本研究的局限性,但恰恰凸显了当前中文医疗 LLMs 所面临的挑战。

表2 LLMs 一览表
Table 2 Comparison list of LLMs

模型	版本	发布时间	领域	访问链接
GPT3.5	GPT3.5-turbo	2022.11.30	通用	https://openai.com/
ChatGLM3	ChatGLM3-6B	2023.10.27	通用	https://github.com/THUDM/ChatGLM3
Baichuan	Baichuan-13B-Chat	2023.07.11	通用	https://github.com/baichuan-inc/Baichuan-13B
PULSE	PLUSE-7B	2023.12.26	医疗	https://github.com/openmedlab/PULSE
BenTsao	houzi3-awq	2024.02.09	医疗	https://github.com/HIT-SCIR/houzi
HuatuoGPT2	HuatuoGPT-II-7B	2023.11.21	医疗	https://github.com/FreedomIntelligence/HuatuoGPT-II
BianQue2	BianQue-2	2023.06.06	医疗	https://github.com/scutecyr/BianQue
ShenNong	—	2023.06.25	中医药	https://github.com/michael-wzhu/ShenNong-TCM-LLM

2.3 硬件配置和提示设计

由于GPT未开源,本研究使用OpenAI的API进行访问GPT3.5,而其他开源模型则下载后在本地Linux系统上部署和调用。本地部署环境配备单卡GPU,型号为L20(48GB),CPU为Intel(R)Xeon(R)Platinum 8474C。提示设计对于LLMs的性能至关重要。一个精心设计的提示能够使LLMs产生准确且切题的回应,从而充分发挥模型的性能^[32]。为确保LLMs发挥最佳表现,本研究为两种实验类型量身定制了提示,以帮助模型有效理解任务要求和问题。本研究通过代码自动从测评基准数据集中提取具体的题型、学科、问题及选项等信息,并将这些内容填充到预设的提示模板中的相应位置,从而生成一个完整的提问。提示模板具体设计如下:

答案预测题模板:“中医学考试【题型】,【答题要求】。【问题】,【选项】。不解释,请回答正确的选项。”

答案推理题模板:“这是一道中医【学科】的问答题,【概念】的【问题】是什么?不解释,请简单回答。”

2.4 评价指标

本研究分别采用准确率和F1值评估模型在单选题和多选题上的答案预测能力。其中,准确率是衡量模型在选择题中选出正确答案的比例,反映了模型在处理有明确答案选择的任务上的正确性。F1值是精确率和召回率的调和平均值,适用于多项选择题中复杂的答案评估。在多项选择题的结果评估中,本实验将答案的每个选项字母均视为独立标签,这意味每个选项的正确或错误都被单独考虑。即当参考答案是ABC,模型答案是BC时,正确率为0,但

因为BC在参考答案中,故精确度会增加,F1值也会相应增加。

同时,采用BLEU^[33]和Rouge^[34]评估模型在答案推理题上生成的答案与参考答案之间的差异,其中,BLEU是评估模型生成答案与参考答案之间的词汇重叠度,主要关注精确度。Rouge是评估模型生成答案与参考答案之间的相似度,侧重于召回率。两个指标分别选择了3种长度的字节片段进行分割计算(如1-gram、2-gram和最长公共子序列L)。

3 结果

3.1 答案预测实验

3.1.1 根据学科分类比较 本研究进一步分析各模型在两个考试中不同学科上的表现,执业医师考试的结果如图3A所示。Baichuan在大部分学科中的表现都是最优的,总正确率为36.39%。所有模型的平均正确率在各个科目中呈显著差异,范围从最低的25.74%到最高的37.75%。说明模型对中医不同学科知识的掌握程度参差不齐,需要针对性地加强模型在薄弱科目的学习能力。ChatGLM3在中医诊断学和中药学科目中表现较为突出,分别达到了46.06%和37.01%的正确率。中医研究生考试的结果如图3B所示,ChatGLM3在大部分学科中的表现较好,总正确率为39.76%,且与在执业医师考试中表现优秀的学科具有一致性。ChatGLM3模型能够在不同考试中展现出相似的优异成绩,说明其在这些学科的知识掌握和应用能力较稳定。卫生法规和医学人文科目是所有模型表现最好的学科,平均正确率达到了37.75%和46.66%,这可能是由于该科目的知识点较为规范和明确,易于模型学习和理解。




图 3 基于考试分类比较的答案预测题结果

Fig. 3 Answer prediction results based on exam classification comparison

3.1.2 根据题型分类比较 在处理中医研究生考试多项选择题的答案预测任务时,不同的 LLMs 展现出对提示指令不同程度的理解能力,如表 3 所示。其中,ChatGLM3 表现最佳,生成的错误答案数量最少为 48 道,对应最高的正确率是 18.96%。相比之下,BenTsao 错误率最高,常无法理解问题含义,正

确率也相应最低仅为 7.50%。GPT3.5 虽然可以根据指示正确生成回答,但是正确率相对较低。这表明不同的 LLMs 在处理多项选择题答案预测任务时指令遵循能力存在显著差异,这种差异直接影响模型的预测准确性。

表 3 基于学科分类比较的答案预测题中多项选择题结果 (%)

Table 3 Multiple choice answer prediction results based on subject classification comparison (%)

学科	GPT3.5		ChatGLM3		Baichuan		BenTsao		PULSE	
	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1
中医基础理论	11.88	71.02	22.98	78.71	13.25	61.04	8.47	62.24	11.43	68.86
中医诊断学	6.88	69.02	23.21	77.62	9.32	63.58	8.86	62.14	6.47	64.56
中药学	9.24	64.18	19.09	76.59	10.37	60.53	6.64	62.09	9.4	64.46
方剂学	11.02	66.65	13.98	73.57	4.66	56.11	5.96	56.17	7.79	63.83
针灸学	8.4	59.17	13.58	74.72	9.88	61.22	4.94	59.15	7.79	63.83
中医内科学	10.28	67.84	17.59	75.44	7.24	62.06	8.2	63.79	10.42	67.68
错误题数	58		48		97		320		236	

通过对 LLMs 在所有单项选择题和多项选择题两种题型中的表现进行比较分析,结果见图 4。在单项选择题中,Baichuan 整体表现优于其他模型,其他模型之间的差距则相对较小。在多项选择题中,与其他模型相比,ChatGLM3 展现出了更强的答题能力和正确率,并且与其他模型拉开了一定差距。在对比两种不同题型的实验结果,可以发现大多数模型在单项选择题答案预测结果中总正确率分值要高于多项选择题的。这一现象可能源于两种题型本身的差异。单项选择题相对简单,只需判断一个答案选项是否正确;而多项选择题则需要同时预测多个答案选项,难度更大,对模型的知识理解和推理能力要求更高。此外,BenTsao 在各学科领域均表现不佳,反映其整体能力较弱。




图4 基于题型分类比较的答案预测题结果

Fig. 4 Answer prediction results based on question type classification comparison

3.2 答案推理实验

在答案推理的实验中,如图5所示,发现所有模型在针灸学问题上的数值较高,Rouge-1达到50.09的高分。这种现象可能是由于模型生成的内容在书写形式上与正确答案相似,尤其是描述腧穴定位时模型生成大量“形似”但内容不正确的答案。这一结果表明,模型经过训练后领域知识的语言表达和结构上的模仿能力增强,但未学会精确的医学知识。所有模型在中药学和方剂学这两个学科上的数值较低,Rouge-1值有15.27的低分。ChatGLM在各个学科中的Rouge-1分值最高分50.09与最低分40.91相差约10,Baichuan在各个学科中的

Rouge-1 分值最高分 50.09 与最低分 29.07 相差约 20,这表明 ChatGLM 在中医领域不同学科中的表现较为稳定,但各个模型在中医各个学科的表现仍有显著差异。

由于 Rouge 和 BLEU 都是基于单词匹配的评价指标,故它们受到生成文本长度的影响,长度差异越小,分值越高。ChatGLM3、GPT3.5 和 Baichuan 三个模型生成的文本长度与参考答案更接近,甚至更短,从而使得它们在 Rouge 和 BLEU 数值相对较高。相比之下,PULSE、BianQue-2、ShenNong 和 HuatuoGPT2 在回答问题时倾向于生成过多的解释或不相关内容,极大地降低了指标数值。




图5 基于学科分类比较答案推理题结果

Fig. 5 Answer reasoning results based on subject classification comparison

将所有学科合并后各模型的总推理结果如表 4 所示, Baichuan 的 BLEU 值较高, 而 ChatGLM3 的 Rouge 值则更为突出。这是由于 BLEU 更注重单词的精确度, 而 Rouge 则更侧重语义相似度。因此, 尽管 Baichuan 生成答案使用了一些相同词语, 但是整体语义偏离了参考答案的本意, 那么 ROUGE 值就会较低。需要注意的是, 即使模型生成的文本在长

度和语义上与参考答案保持一致性, 也不能保证其生成内容的正确性。虽然 BLEU 和 Rouge 在评估中医领域的文本时可能不够准确, 例如它们容易受到文本长度和表面语义歧义的影响, 但仍可以大致正确反映模型回答的效果。ChatGLM3 和 Baichuan 在多个学科问题的回答中表现突出, 总体展示出在中医领域较高的文本生成质量和准确性。

表 4 基于模型分类比较的答案推理题结果

Table 4 Answer reasoning results based on model classification comparison

模型	指标					
	BLEU-1	BLEU-2	BLEU-4	Rouge-1	Rouge-2	Rouge-L
GPT3.5	20.71	8.71	1.97	32.68	11.06	20.64
ChatGLM3	21.68	11.90	4.80	44.64	21.31	25.68
Baichuan	24.72	12.42	4.19	38.88	16.08	25.44
PULSE	14.21	6.02	1.65	30.41	10.63	18.19
BianQue-2	8.28	2.86	0.56	23.25	6.44	8.89
ShenNong	9.26	2.28	0.26	21.28	4.49	10.05
HuatuoGPT2	12.24	5.27	1.42	33.69	12.45	17.97

3.3 总体比较

如表 5 所示, 在答案预测任务中 Baichuan 在单项选择题中准确率最高, 为 36.07%; ChatGLM3 在多项选择题中准确率和 F1 值最高, 为 18.96% 和 76.31%。答案推理实验的结果显示, Baichuan 在 BLEU-1 分值最高, 为 24.71; ChatGLM3 在 Rouge-1 分值最高, 为 44.64。PULSE 在 5 个中文医疗模型中表现最优, 尽管参数规模远小于 GPT3.5, 其测评

结果却与 GPT3.5 不相上下, 充分展示了特定领域微调后模型的提升效果。在答案预测实验中 LLMs 在中医经典方面的分数较低, 这可能与中医经典相关的训练语料相对较少, 以及中医古籍中的文言文难以理解有关。目前, 已有学者开始尝试训练专门针对古籍的 LLMs, 如 HuangDi^[35]、XunziALLM^[36], 以期提高模型在理解和应用古籍知识方面的能力。

表 5 LLMs 测评结果

Table 5 Results of the LLMs evaluation

模型	答案预测/%		答案推理			
	单选 Acc	多选 Acc	BLEU-1	BLEU-2	Rouge-1	Rouge-2
GPT3.5	27.56	9.76	20.71	8.71	32.68	11.06
ChatGLM3	34.27	18.96	21.68	11.90	44.64	21.31
Baichuan	36.07	8.98	24.72	12.42	38.88	16.08
PULSE	27.94	9.39	14.21	6.02	30.41	10.63
BenTsao	23.74	7.50	—	—	—	—
BianQue-2	—	—	8.28	2.86	23.25	6.44
ShenNong	—	—	9.26	2.28	21.28	4.49
HuatuoGPT2	—	—	12.24	5.27	33.69	12.45

4 讨论

随着越来越多的研究关注医疗 LLMs 的研发, 和中医学的复杂性及对专业知识的高度依赖, 对 LLMs 提出了较高的准确性和安全性的要求。为解决当前医疗 LLMs 评估中缺乏中医测评基准这一问题, 本研究创新性地构建了一个聚焦于中医领域的

多学科、多题型的中医疗测评基准数据集并且对 8 个 LLMs 在答案预测能力和答案推理能力两个维度进行评测。该中医疗测评基准数据集包含了 29 506 道答案预测题和 1 691 道答案推理题两种题型, 答案预测题是有标准答案的单项选择题和多项选择, Baichuan 在单项选择题中准确率最高、ChatGLM3 在多

项选题中准确率和 $F1$ 值最高;答案推理题是从教科书中内容构建的问答题,Baichuan 在 BLEU-1 分值最高、ChatGLM3 在 Rouge-1 分值最高。本数据集的构建为评估和提升 LLMs 在中医领域的知识掌握能力提供了有价值的参考。然而,所有参与测试的模型在选择题上的准确率均未超过 60%,说明在真实世界中 LLMs 难以通过考试,这表明 LLMs 在中医药领域的性能仍有很大的提升空间,LLMs 提供的回答只可作为参考,无法取代专业医疗建议^[37]。

在本研究中有以下 4 点发现:①通用 LLMs 整体表现略优于中文医疗 LLMs,且中文医疗 LLMs 难以遵循精确指令完成答案预测任务。微调虽能提升 LLMs 在特定任务中的语言表达,尤其是微调数据集和评估数据集一致时效果明显^[38]。但是由于大模型参数庞大,微调过程中容易出现过拟合和灾难性遗忘^[39]现象,导致模型性能退化和泛化能力变差^[40-41]。相比之下,通用模型凭借技术积累和资源优势,通过快速迭代引领国内 LLMs 发展。②中文医疗模型中,PULSE 表现最优,其原因与微调数据集相关。微调数据集的质量和规模显著影响模型性能^[42],更多样化的数据集可以帮助缓解灾难性遗忘这一现象^[43]。在本研究中 BenTsao、ShenNong、HuatuoGPT2 是利用 ChatGPT 围绕医学数据构建问答的指令微调数据集。但是由于 LLMs 的安全限制,ChatGPT 会生成了大量类似“无法回答问题,建议咨询医生。”的重复回应。Danny 等^[44]研究表明模型训练时重复数据会显著降低其性能,而 PULSE 凭借规模最大最丰富的 40 万个医学和通用领域指令数据集在中文医疗 LLMs 中表现最优。③BianQue-2 的评估结果分值最低,这与其基础模型相关。BianQue-2 是以 GLM-6B 为基础模型微调而来,其能力受限于基础模型,而 ChatGLM3 是在 GLM-6B 的基础上使用更多样的训练数据、更充分的训练步数、模型更复杂,故效果更好。④通用模型中,ChatGLM3 和 Baichuan 整体表现比 GPT3.5 好,这与模型预训练阶段语料库相关。ChatGLM3 和 Baichuan 相比 GPT3.5 在预训练阶段使用了更广泛的中文语料库,因此对中医问题的理解能力更强,这一观点得到了 Zhu 等^[45]研究的进一步支持。

虽然大语言模型因其内部机制复杂不透明,被称为“黑箱”系统,其可解释性是一大研究难题^[46],但是通过测评实验提示在今后微调模型时应注重基础模型选择、训练数据质量及多样性和微调技术等。

本研究也存在一定的不足和局限性,如测评基准数据集规模有限和测评的模型数量覆盖不全。因此,未来研究计划是纳入真实中医病例数据等扩大和完善基准,选择更多具有代表性的模型,并引入专家评估等以进一步验证和探究各模型在中医领域各方面性能表现及其稳定性,全面反映 LLMs 在中医药领域中的实际应用和性能状况。为攻破构建高度可信的中医智能诊疗 LLM 这一关键挑战^[47],本研究建议可根据下游任务的具体需求,灵活结合使用微调(Fine-tuning)、提示工程(Prompt Engineering)、检索增强生成^[48](Retrieval-Augmented Generation, RAG)等方法,通过持续迭代、评估和改进来不断提升优化模型表现。

参考文献:

- [1] BIRHANE A, KASIRZADEH A, LESLIE D, et al. Science in the age of large language models[J]. Nat Rev Phys, 2023, 5(5): 277-280.
- [2] YANG J, JIN H, TANG R, et al. Harnessing the power of LLMs in practice: A survey on ChatGPT and beyond[J]. ACM Trans Knowl Discov Data, 2024, 18(6): 1-32.
- [3] SCHULMAN J, ZOPH B, KIM C, et al. Introducing ChatGPT [EB/OL]. (2022-11-30) [2024-12-01]. <https://openai.com/index/chatgpt/>.
- [4] SHEN Y, HEACOCK L, ELIAS J, et al. ChatGPT and other large language models are double-edged swords[J]. Radiology, 2023, 307(2): 230163.
- [5] ACHIAM J, ADLER S, AGARWAL S, et al. GPT-4 technical report[EB/OL]. (2024-03-04) [2024-12-01]. <http://arxiv.org/abs/2303.08774>.
- [6] ANTHROPIC. Claude 3 haiku: Our fastest model yet [EB/OL]. (2024-03-14) [2024-12-01]. <https://www.anthropic.com/news/claude-3-haiku>.
- [7] GLM T, ZENG A, XU B, et al. ChatGLM: A family of large language models from GLM-130B to GLM-4 all tools [EB/OL]. (2024-07-30) [2024-12-01]. <http://arxiv.org/abs/2406.12793>.
- [8] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: Open and efficient foundation language models [EB/OL]. (2023-02-27) [2024-12-01]. <http://arxiv.org/abs/2302.13971>.
- [9] DU Z, QIAN Y, LIU X, et al. GLM: General language model pre-training with autoregressive blank infilling[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin, Ireland: Association for Computational Linguistics, 2022: 320-335.
- [10] WORKSHOP B, SCAO T L, FAN A, et al. BLOOM: A 176B-parameter open-access multilingual language model [EB/OL]. (2023-06-27) [2024-12-01]. <http://arxiv.org/abs/2211.05100>.
- [11] ZHANG H, CHEN J, JIANG F, et al. HuatuoGPT: towards training language model to be a doctor[C]. Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore: Association for Computational Linguistics, 2023: 10859-10885.
- [12] WANG H, LIU C, XI N, et al. HuaTuo: Tuning LLaMA model with Chinese medical knowledge [EB/OL]. (2023-04-14) [2024-12-01]. <http://arxiv.org/abs/2304.06975>.
- [13] YANG S, ZHAO H, ZHU S, et al. Zhongjing: Enhancing the Chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue [EB/OL]. (2023-12-28) [2024-12-01]. <http://arxiv.org/abs/2308.03549>.
- [14] LIU L, YANG X, LEI J, et al. A survey on medical large language models: Technology, application, trustworthiness, and future directions [EB/OL]. (2024-06-06) [2024-12-01]. <http://arxiv.org/abs/2406.03712>.
- [15] HE J, FU M, TU M. Applying deep matching networks to Chinese

- medical question answering: A study and a dataset[J]. BMC Med Inform Decis Mak, 2019, 19(S2): 52.
- [16] JIN D, PAN E, OUFATTOLE N, et al. What disease does this patient have? A large-scale open domain question answering dataset from medical exams [EB/OL]. (2021-05-21) [2024-12-01]. <https://www.preprints.org/manuscript/202105.0498/v1>.
 - [17] PAL A, UMAPATHI L K, SANKARASUBBU M. MedMCQA: A large-scale multi-subject multi-choice dataset for medical domain question answering[C]. Proceedings of the Conference on Health, Inference, and Learning. Eindhoven, The Netherlands: PMLR, 2022; 248-260.
 - [18] ZHANG N, CHEN M, BI Z, et al. CBLUE: A Chinese biomedical language understanding evaluation benchmark[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin, Ireland: Association for Computational Linguistics, 2022; 7888-7915.
 - [19] ZHU W, WANG X, ZHENG H, et al. Prompt CBLUE: A Chinese prompt tuning benchmark for the medical domain [EB/OL]. (2023-10-22) [2024-12-01]. <http://arxiv.org/abs/2310.14151>.
 - [20] SINGHAL K, AZIZI S, TU T, et al. Large language models encode clinical knowledge[J]. Nature, 2023, 620(7972): 172-180.
 - [21] LIU J, ZHOU P, HUA Y, et al. Benchmarking large language models on CMExam: A comprehensive Chinese medical exam dataset[C]. Proceedings of the 37th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2024; 52430-52452.
 - [22] WANG X, CHEN G, SONG D, et al. CMB: A comprehensive medical benchmark in Chinese[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics; Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024; 6184-6205.
 - [23] CAI Y, WANG L, WANG Y, et al. MedBench: A large-scale Chinese benchmark for evaluating medical large language models[J]. Proc AAAI Conf Artif Intell, 2024, 38(16): 17709-17717.
 - [24] CHANG Y. QiZhenGPT: An open source Chinese medical large language model[EB/OL]. (2024-08-09) [2024-12-01]. <https://github.com/CMKRG/QiZhenGPT>.
 - [25] CHEN J, WANG X, JI K, et al. HuatuoGPT-II, one-stage training for medical adaption of LLMs[EB/OL]. (2024-09-15) [2024-12-01]. <http://arxiv.org/abs/2311.09774>.
 - [26] YANG A, XIAO B, WANG B, et al. Baichuan 2: Open large-scale language models[EB/OL]. (2023-09-20) [2024-12-01]. <http://arxiv.org/abs/2309.10305>.
 - [27] ZHANG X, XUE K, ZHANG S. PULSE: Pretrained and unified language service engine[EB/OL]. [2024-12-01]. <https://github.com/openmedlab/PULSE>.
 - [28] DU Y, ZHAO S, CAI M, et al. Don't ignore dual logic ability of LLMs while privatizing: A data-intensive analysis in medical domain[EB/OL]. (2024-02-23) [2024-12-01]. <http://arxiv.org/abs/2309.04198>.
 - [29] CHEN Y, WANG Z, XING X, et al. BianQue: Balancing the questioning and suggestion ability of health LLMs with multi-turn health conversations polished by ChatGPT[EB/OL]. (2023-12-04) [2024-12-01]. <http://arxiv.org/abs/2310.15896>.
 - [30] LI J, WANG X, WU X, et al. Huatuo-26M, a large-scale Chinese medical QA dataset[EB/OL]. (2023-05-02) [2024-12-01]. <http://arxiv.org/abs/2305.01526>.
 - [31] ZHU W, YUE W, WANG X. ShenNong-TCM: A traditional Chinese medicine large language model[EB/OL]. [2024-12-01]. <https://github.com/michael-wzhu/ShenNong-TCM-LLM>.
 - [32] LIN Z. How to write effective prompts for large language models[J]. Nat Hum Behav, 2024, 8(4): 611-615.
 - [33] PAPINENI K, ROUKOS S, WARD T, et al. BLEU: A method for automatic evaluation of machine translation[C]. Proceedings of the 40th Annual Meeting on Association for Computational Linguistics - ACL '02. Philadelphia, Pennsylvania: Association for Computational Linguistics, 2002; 311.
 - [34] LIN C Y. ROUGE: A package for automatic evaluation of summaries[C]. Text Summarization Branches Out. Barcelona, Spain: Association for Computational Linguistics, 2004; 74-81.
 - [35] 张君冬, 杨松桦, 刘江峰, 等. AIGC 赋能中医古籍活化: Huang-Di 大模型的构建[J]. 图书馆论坛, 2024, 44(10): 103-112.
 - [35] ZHANG J D, YANG S H, LIU J F, et al. AIGC empowering the revitalization of ancient books on traditional Chinese medicine: Building the Huang-Di large language model[J]. Libr Trib, 2024, 44(10): 103-112.
 - [36] WANG D. XunziALLM: Xunzi series large language model[EB/OL]. [2024-12-01]. <https://github.com/Xunzi-LLM-of-Chinese-classics/XunziALLM>.
 - [37] ALBERTS I L, MERCOLLI L, PYKA T, et al. Large language models (LLM) and ChatGPT: What will the impact on nuclear medicine be? [J]. Eur J Nucl Med Mol Imaging, 2023, 50(6): 1549-1552.
 - [38] SONI S, ROBERTS K. Evaluation of dataset selection for pre-training and fine-tuning transformer language models for clinical question answering[C]. Proceedings of the Twelfth Language Resources and Evaluation Conference. Marseille, France: European Language Resources Association, 2020; 5532-5538.
 - [39] XU R, LUO F, ZHANG Z, et al. Raise a child in large language model: Towards effective and generalizable fine-tuning[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021; 9514-9528.
 - [40] PHANG J, FEVRY T, BOWMAN S R. Sentence encoders on STILTs: Supplementary training on intermediate labeled-data tasks [EB/OL]. [2019-02-27] [2024-12-01]. <http://arxiv.org/abs/1811.01088>.
 - [41] LEE C, CHO K, KANG W. Mixout: Effective regularization to finetune large-scale pretrained language models[EB/OL]. [2020-01-23] [2024-12-01]. <https://arxiv.org/abs/1909.11299>.
 - [42] MEHRAFARIN H, RAJAEI S, PILEHVAR M T. On the importance of data size in probing fine-tuned models[C]. Findings of the Association for Computational Linguistics; ACL 2022. Dublin, Ireland: Association for Computational Linguistics, 2022; 228-238.
 - [43] LUO Y, YANG Z, MENG F, et al. An empirical study of catastrophic forgetting in large language models during continual fine-tuning[EB/OL]. (2024-04-02) [2024-12-01]. <http://arxiv.org/abs/2308.08747>.
 - [44] HERNANDEZ D, BROWN T, CONERLY T, et al. Scaling laws and interpretability of learning from repeated data [EB/OL]. (2022-05-21) [2024-12-01]. <http://arxiv.org/abs/2205.10487>.
 - [45] ZHU L, MOU W, LAI Y, et al. Language and cultural bias in AI: Comparing the performance of large language models developed in different countries on traditional Chinese medicine highlights the need for localized models[J]. J Transl Med, 2024, 22(1): 319.
 - [46] ZHAO H, CHEN H, YANG F, et al. Explainability for large language models: A survey[J]. ACM Trans Intell Syst Technol, 2024, 15(2): 1-38.
 - [47] 杨涛, 王欣宇, 朱垚, 等. 大语言模型驱动的中医智能诊疗研究思路与方法[J]. 南京中医药大学学报, 2023, 39(10): 967-971.
 - [47] YANG T, WANG X Y, ZHU Y, et al. Research ideas and methods of intelligent diagnosis and treatment of traditional Chinese medicine driven by large language model[J]. J Nanjing Univ Tradit Chin Med, 2023, 39(10): 967-971.
 - [48] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]. Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020; 9459-9474.

(编辑:叶亮)