

文章编号: 1003-0077(2026)01-0085-15

负质: 古汉语文本理解与生成能力评测基准

赵尚卿¹, 兰 曼^{1,2}, 柏晓鹏^{2,3}, 徐默凡³, 任育培^{1,2}, 周裕浩¹

- (1. 华东师范大学 计算机科学与技术学院, 上海 200062;
2. 华东师范大学 上海教育人工智能研究院, 上海 200062;
3. 华东师范大学 中国语言文学系, 上海 200062)

摘 要: 该文提出负质(Fùxì)基准, 一个面向大语言模型古汉语文本理解与生成能力的系统性评测框架。负质涵盖 21 项任务, 创新性地设计了多种开放式生成、格式约束生成类型的全新评测任务, 用于评估大语言模型在古汉语文本生成中多个维度的能力。基准数据来源多元可靠, 且经过严格整理。针对古汉语生成任务特点, 采用规则约束与自动化评测相结合的方法, 对十八种主流大语言模型进行了系统评测。结果显示, 当前大模型在理解型任务上表现优异(平均 70.30%), 但在需要专业知识和深层文化理解运用的生成任务上性能差异显著, 正确率平均下降了 30~40 个百分点。负质基准提出的自动化测评框架显著提升了评测效率与一致性, 为古汉语处理技术发展和文化遗产数字化传承提供了重要的评测工具和基准参考。

关键词: 古汉语; 大语言模型; 测评基准

中图分类号: TP391

文献标识码: A

Fùxì: A Benchmark for Evaluating on Ancient Chinese Text Understanding and Generation

ZHAO Shangqing¹, LAN Man^{1,2}, BAI Xiaopeng^{2,3}, XU Mofan³, REN Yupei^{1,2}, ZHOU Yuhao¹

- (1. College of Computer Science and Technology, East China Normal University, Shanghai 200062, China;
2. Shanghai Institute of Artificial Intelligence for Education, East China Normal University, Shanghai 200062, China;
3. Department of Chinese Language and Literature, East China Normal University, Shanghai 200062, China)

Abstract: Fuxi is presented as a systematic evaluation framework for large language models' capabilities in Ancient Chinese text understanding and generation. The benchmark includes 21 tasks of open-ended generation or pattern-constrained generation to assess Ancient Chinese text generation abilities across multiple dimensions. The benchmark collects data from reliable sources and applied rigorous curation procedures. Experiments on eighteen mainstream large language models show that current models excel at comprehension tasks (averaging 70.30%) but exhibit a drop of approximately thirty to forty percentage points on generation tasks requiring professional knowledge and deep cultural understanding. Pattern-constrained generation tasks reveal particularly notable performance differences. Fuxi provides an evaluation tool and benchmark reference for Ancient Chinese processing technology development and cultural heritage digitization.

Keywords: ancient Chinese; large language models; benchmark

0 引言

古汉语(包括文言文、诗词歌赋等)作为中国语言的书面形式已在东亚地区使用了两千多年, 深刻影响了该地区的文化和知识发展^[1-2], 也是目前中学

语文教学的重要内容。据统计, 北京大学 CCL 语料库^[3]和北京语言大学 BBC 语料库^[4]包含的古汉语语料分别为约两亿和 20 亿字符, 殆知阁古代文献藏书语料库也包含约 33 亿字符^[5]。这些数据涵盖文史哲、医工农, 以及宗教、诗词、技艺等领域, 具有重要的文化和学术价值。将丰富的古汉语语料与当前

收稿日期: 2025-05-29 定稿日期: 2025-08-20

基金项目: 国家自然科学基金(72192820, 72192824); 上海市教委“人工智能促进科研范式改革赋能学科跃升计划”(2024AI02004); 中央高校基本科研业务费(2024QKT004)

先进的信息技术结合起来,为古汉语教学和研究提供便利,对推动中华优秀传统文化的传承与发展具有重要意义。

近年来,随着自然语言处理技术的快速发展,古汉语相关的研究也取得了显著进步。传统的古汉语自然语言处理主要聚焦于分词、断句、标点和命名实体识别等基础任务,并多依赖于规则和统计方法^[6]。随着大语言模型(LLM)在现代汉语处理中的突破

性进展,其在古汉语领域的应用潜力引起了广泛关注。然而,如表 1 所示,即使是目前最先进的大语言模型之一的 GPT-4o^[7],也在古汉语相关的任务上表现不佳。尽管这些模型通常可以从多个候选项中选出正确的答案,但是在生成古汉语形式的文本方面,它们的表现仍有待提高。这凸显了古汉语相关任务的复杂性,即写作生成难于理解和选择。

表 1 GPT-4o 模型于部分负质测评任务的交互示例

任务	正确/参考答案	GPT-4o 的回复
古汉语阅读理解	下列诗句中,描绘春日景象的是() A.春风又绿江南岸,明月何时照我还? B. 春眠不觉晓,处处闻啼鸟。 C.春风得意马蹄疾,一日看尽长安花。 D. 春水初生,春林初盛,春风十里,不如你。	
	B	描绘春日景象的是:B. 春眠不觉晓,处处闻啼鸟。
逆向诗词翻译	根据以下翻译给出对应的古诗词原文。在这个地方荆轲告别燕太子丹,壮士悲歌壮气,怒发冲冠。那时的人已经都不在了,今天的易水还是那样的寒冷。	这段翻译对应的古诗词原文是唐代骆宾王所作的《易水送别》,原文如下:《易水送别》作者:骆宾王
	题目:于易水送人 / 于易水送别 作者:骆宾王 此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒。	此地别燕丹,壮士发冲冠。 昔人已乘黄鹤去,此地空余易水寒。
文言文翻译	将这句话翻译为现代汉语:立经陈纪,轻重同得,后可以为万世法程,虽有愚幼不肖之嗣,犹得蒙业而安,至明也。	建立并明确了法律制度,轻重缓急都能够得到恰当处理,之后可以作为世世代代的法规准则,即使后代中有愚蠢年幼或不才的人继承,也能够享受其成就而安然生活,这才是高明的治理。
	确立准则,颁布纲纪,轻重缓急处理得宜,而后可以成为万世的法式,即使有愚笨不成器的后代,还能承受祖业得到安定,这是最英明的了。	
词牌填词	按照提供的词牌名和题目写一首词。必须严格遵守词牌的格律要求。 词牌:临江仙; 题目:徐州	临江仙·徐州 金马苍茫垂古道,云浮九顶青山。大彭故里梦犹连。
	如此江城烟草绿,山庭燕子飞飞。英雄也怯暮春时,落花风底,含泪对空枝。 一自台城春去后,年年幽恨谁知。无由相见但相思,觉来窗暗,惆怅绿阴肥。	黄河千里远,秋水映楼间。 酒肆灯火摇驿路,巷街人语喧喧。几番风雨说流年。 英雄曾逐鹿,凭吊意悠然。

尽管大语言模型的研究进展如火如荼,但其在古汉语相关任务上的能力尚未得到系统性评估,尤其是古汉语文本生成能力的测评严重缺失。建立一个全面的古汉语测评基准对于推动该领域发展、促进模型能力提升具有重要意义。现有的测评基准如 C-CLUE^[8] 主要聚焦于信息抽取, WYWEB^[9] 涵盖了多种传统古汉语处理任务,但其任务设计难以适应偏向实际场景的大模型能力评估。面向大模型古汉语理解能力的 ACLUE^[10] 和 AC-EVAL^[11] 等,虽然在评估模型特定任务表现方面做出了重要贡献,但大多仍以选择题为主,缺乏对模型生成连贯且符合古汉语语法、文化和风格要求的文本能力的通用评测,也难以有效检测模型生成过程中的幻觉现象。

为解决这些局限性,本文参考语言测试领域的交际语言模型理论^[12],设计构建了负质(Fùxì)基准,一个面向大语言模型古汉语理解与生成能力的系统性评测框架。^① 负质基准具有如下主要特点:

(1) 兼顾理解与生成两大任务类型,涵盖 21 项精心设计的评测任务(表 2),实现对大语言模型古汉语能力的多维度考察。

(2) 创新性地引入多种开放式生成任务,重点评估模型生成连贯、符合古汉语语法与文化规范文本的语言交际能力,并能够有效识别模型生成过程中的幻觉现象。

^① 负质是龙生九子中的第八子,喜好读书识字,常被雕刻于碑文之上。以此为名,寓意本基准承载和评测古汉语文化遗产的初心。

(3) 针对古汉语生成任务的特殊性,提出了结合规则约束与大模型自动评测的混合评估方法,显著提升了评测效率与一致性。

上述设计为推动古汉语处理技术发展和模型能力提升提供了科学、全面的评测基准。

本文的主要贡献可概括如下:

(1) 构建了负质测评基准,旨在全面评估大语言模型在古汉语文本上的理解能力与生成能力。

(2) 设计了区别于传统古汉语处理任务的新型任务,重点评估模型的古汉语文本生成能力及其可

能产生的幻觉现象。

(3) 针对古汉语生成任务的特点,提出了新的自动评估方法,提高了评测效率与一致性。

(4) 系统评测了 18 种主流大语言模型,揭示了当前模型在古汉语处理中的能力边界和差距。

负质基准的数据和评估脚本已全部开源于 <https://github.com/cubenlp/FuxiBench>,为古汉语处理相关研究提供统一、全面的评测框架,推动该领域模型能力的持续提升,助力古汉语教学和研究的信息化和智能化发展。

表 2 负质基准任务概述(包括任务描述、评估指标及样本统计)

任务名称	任务描述	任务类型	评估指标	样本数量	平均输入长度	平均答案长度
古汉语阅读理解 (Ancient Chinese RC, ACRC)	选择题形式的文言文阅读理解	理解型	准确率	300	814.28	1.00
成语阅读理解 (Idiom RC, IRC)	选择题形式的成语理解	理解型	准确率	1000	159.54	1.00
中医辨证阅读理解 (TCM Syndrome RC, TCMSRC)	选择题形式的中医辨证	理解型	准确率	1098	543.93	1.00
通假字问答 (Loan Character QA, LCQA)	通假字识别问题回答	生成型	准确率	500	37.95	16.88
歇后语问答 (Allegorical Saying QA, ASQA)	歇后语问答,完成下半句	生成型	准确率	553	19.89	5.26
书籍作者 Book Author, BA)	给定书籍名称,回答作者	生成型	准确率	384	17.37	2.64
书籍朝代 Book Dynasty, BD)	给定书籍名称,回答所属朝代	生成型	准确率	372	22.26	1.12
书籍类别划分 (Book Collection Classification, BCC)	给定书籍名称,分类到十个类别之一	生成型	准确率	532	52.65	2.00
诗词创作 Poetry Generation, PG)	根据主题词创作诗词	生成型	准确率	300	27.48	89.23
诗句溯源 (Poetry Line Source Tracing, PLST)	识别诗句的出处	生成型	准确率	400	25.22	11.46
名言溯源 (Famous Quote Source Tracing, FQST)	识别名言名句的出处	生成型	准确率	200	29.41	10.06
成语溯源 (Idiom Source Tracing, IST)	给出成语的来源	生成型	准确率	962	14.17	40.61
逆向诗词翻译 (Inverse Poetry Translation, IPT)	根据现代汉语的译文给出原始诗词	生成型	准确率	300	252.08	152.99
诗词翻译 (Poetry Translation, PT)	将诗词翻译成现代汉语	生成型	BLEU	300	145.79	213.91
文言文翻译 (Classical Chinese Translation, CCT)	将古汉语文本翻译成现代汉语	生成型	BLEU	1000	36.33	35.97
诗词赏析(Poetry Appreciation, PA)	对给出的诗词进行赏析	生成型	BLEU	109	112.70	1312.32
成语解释(Idiom Explanation, IE)	对给出的成语进行解释	生成型	BLEU	1236	14.10	20.43
中医问答(TCM QA, TCMQA)	根据中医文本回答问题	生成型	BLEU	740	385.06	47.28
处方解释(Prescription Explanation, PE)	对给出的中医处方进行解释	生成型	BLEU	404	19.74	70.11
对联生成(Couplet Generation, CG)	根据上联生成下联	生成型	格式准确率	500	27.91	13.91
词牌填词(Ci Generation, CiG)	按照指定词牌格式填词	生成型	格式准确率	300	49.81	79.35

1 相关工作

1.1 中文语言模型测评基准

近年来,中文语言模型评估基准的发展取得了显著进展。早期的测评基准如 MMCU^[13],专注于通过标准考试题目的多项选择题评估模型在不同学科领域的表现,突出其在学科知识覆盖广度上的优势,但主要局限于封闭式理解任务。C-Eval^[14]则进一步扩展了学科门类和题型,强调多层次、多学科的综合评测能力,但同样以现代汉语为主,缺乏对古汉语任务的系统覆盖。CMMLU^[15]和 SuperCLUE^[16]等后续基准结合了封闭式和开放式任务,提升了推理能力和语言理解能力的评测深度,SuperCLUE 还引入了部分生成类任务以考察模型的创造性表达能力。然而,在这些主流基准中,古汉语相关任务占比极低(如 C-Eval 和 SuperCLUE 中古汉语任务占比均不足 1%),部分基准甚至完全缺失古汉语相关评测,导致模型在古汉语领域的能力难以被充分检验。

1.2 古汉语测评基准

鉴于古汉语的特殊性,通常需要专门的资源和评估工具来评估其历史、文学和句法复杂性。例如,GuNER^[17]和 EvaHan2025^[18]针对古汉语命名实体识别,GuwenEE^[19]用于古汉语事件抽取,C-CLUE^[8]聚焦于古汉语信息抽取和理解,CCP-KG^[20]和 CQY^[21]分别面向古诗情感分析和知识图谱构建。针对跨时代文本理解和翻译,尔雅^[22]和 EvaHan2023^[23]等数据集专门解决古今汉语间的句法、语义映射。近期如 ACHNLU^[24]、ACLUE^[10]和 AC-EVAL^[11]等基准,分别从理解、综合和多维度角度对古汉语任务进行评测,但大多以选择题为主,难以系统性考察模型生成古汉语文本的能力。值得注意的是,在目前公开的基准中,生成类古汉语任务占比普遍低于 10%,如 ACLUE 和 AC-EVAL 均是选择题形式,未覆盖文白翻译、诗词创作、对联生成等开放式生成任务。尽管目前已经有九歌^[25]和语笙^[26]等系统展示了生成古代诗词的潜力,以及 CharPoet^[27]通过对大语言模型的词表进行剪枝从而改进其生成古诗文能力的研究,但对大语言模型在多种任务场景下输出古汉语文本能力的系统性评估研究仍然相对匮乏。

1.3 大语言模型评估指标

针对古汉语文本生成任务,评估方法面临诸多独特挑战,亟需结合古汉语语言特点设计专门的评测指标。传统的自动化指标如 BLEU^[28]、ROUGE^[29]和 METEOR^[30],虽然在现代文本生成任务中应用广泛,但在古汉语场景下往往难以全面反映文本的结构规范、语言风格及文化内涵。例如,BLEU 和 ROUGE 主要基于 n -gram 重叠,难以捕捉古汉语诗词中的格律、对仗和意境表达,实验中常出现 BLEU 分数较低但人工评价较高的情况。此外,古汉语文本短小精炼、表达多样,导致自动指标对同义表达和创新性生成的容忍度较低。另外,人工评测作为补充测评方案,通常由具备专业知识背景的评审专家从准确性、流畅性等维度对模型生成结果进行细致评价,但其效率低、成本高,难以满足大规模模型开发需求^[31]。近年来,部分研究尝试引入"LLM-as-a-judge"范式,即利用如 GPT-4、GPT-3.5-Turbo 等大语言模型作为自动化评测代理^[31],该方法在提升评测效率和一致性方面具有优势,尤其适用于大规模、客观性较强的任务,但在主观性强、文化性要求高的古汉语生成任务中,仍存在评判标准不稳定、对细节把握不足等局限。本文根据负质基准中任务的特点,设计了结合规则约束与大模型自动评测的混合评估方案,兼顾评测效率与科学性。

2 负质基准构建

2.1 任务设计

与选择题形式的 ACLUE 和 AC-EVAL 不同,负质以测评大语言模型以生成方式输出古汉语相关知识的能力为核心,兼顾了古汉语理解能力的测评。这一创新启发自 Bachman 的交际语言能力模型(Communicative Language Ability, CLA)^[12]:仅测试 LLM 输出选项的做题能力是不够的,应该考察其作为语言使用者进行沟通的能力。因此,负质在保留了选择题形式的理解型任务(Reading Comprehension, RC)后,收集了一系列经典的古汉语生成任务(如文白翻译、诗词鉴赏、问答等),并设计了全新的开放问答任务,要求模型自由生成答案。这些答案大都是知识性较强的古籍名称、作者、朝代,成语、诗词名句的出处,以及通假字、歇后语和整首诗词等,考察模型对古汉语知识的记忆和检索能

力。相比选择题形式的理解型任务,这样的设计能够更全面地检测大语言模型在古汉语任务中的幻觉现象。

最终,在以输出形式划分的理解任务和生成任务两大类的基础上,本文将生成任务进一步分为开放问答(Question Answering, QA)类任务、基于理解的生成任务(Text Generation, TG)和格式约束的生成任务(Pattern-constrained Generation, PG)。开放问答类任务评估其语言知识,即记忆和输出真实可靠古汉语知识的能力;文本生成类任务关注其社会语言能力,即实现古汉语到现代汉语的实用映射;而格式约束的生成任务则进一步检验其语用能力,如理解并应用对仗、格律等古汉语写作规范的能力。此外,借鉴语言测试领域的 Assessment Use Argument (AUA) 理论^[32],我们确保每项测评任务的设计兼具效度(如准确测量目标能力)和实用性(如服务于古汉语教育或研究需求)。

2.2 数据构建

负质基准的数据构建采用多源融合策略:

(1) 基础数据来源于权威古籍知识库,包括殆知阁古籍数据库、中国古诗文数据库和中医古籍文献库等。

(2) 复用并扩展了已有的高质量古汉语评测数据集,如尔雅^[22]和 WYWEB^[9]等。

为保证数据质量,本文采用了严格的数据处理流程:首先,利用自动化脚本进行数据预处理,包括去重、格式统一等;其次,由古汉语领域专家进行人工校验,确保数据的准确性和一致性;最后,对于格式规范的任务(如诗句补全),设计了专门的验证程序以确保数据符合古汉语的结构要求。这一多层次的质量控制机制有效保证了负质基准数据的可靠性。如前文所述,测评数据共分为四大类,具体构建过程描述如下:

多项选择阅读理解 此类任务包括多种用于评估古汉语文本阅读理解能力的多项选择题。本文纳入了来自 WYWEB^[9]的古汉语阅读理解任务和成语阅读理解任务。此外,考虑到中医(TCM)是古代中国文化遗产的重要组成部分、且大多以古汉语形式记载传承,负质基准基于中医辨证数据集^[33]构建了中医辨证阅读理解任务(TCMSRC),要求大语言模型根据描述的患者病历从四种中医证型中选择最合适的诊断。

开放式问答 此类任务评估大语言模型的深度理解知识的能力,要求它们生成答案而非从选项中

选择,从而揭示其潜在的幻觉现象。除了常规的通假字识别^[34]、歇后语补全任务^[35],负质基于殆知阁数据库^[36]构建了三个全新任务,分别要求大语言模型根据书名给出作者、历史朝代、书籍的藏集类别。为了考察大语言模型对于古汉语文化遗产的记忆程度,负质引入了溯源类任务,要求大语言模型给出诗句和名言的出处,解释成语的来源等。此外,逆向诗词翻译是一项特别具有挑战性的任务,大语言模型必须从现代汉语翻译中重构古诗词原文。这对于人类是一项十分简单的任务,但大语言模型却很难自主完成。

基于理解的生成 此类任务包括使用 BLEU 评分评估输出质量的生成任务,通过衡量与参考答案的相似性来评估,任务数据通过从专业数据库^[35,37]和已有数据集^[38-39]筛选改造获得。任务包括:古诗词翻译、古文翻译、诗歌赏析、成语解释、中医医书问答、处方解释。

格式约束的生成 此类任务评估大语言模型在生成符合古汉语文学严格格式和韵律规则文本方面的能力。古典诗词、对联等体裁对字数、平仄、押韵、对仗等均有明确要求,这些规则不仅影响文本的形式美,也直接关系到文学作品的韵律与艺术价值。负质基于开源的对联数据库^[40]和词牌数据库^[41]设计了如下两项具有代表性的任务:

(1) 对联生成:要求模型在给定上联的基础上生成下联。下联需严格遵循对仗、平仄、字数等格式规则,体现汉语对联的工整性与对称美。

(2) 词牌填词:要求模型根据指定词牌和主题,完整创作一首词。词作需严格遵循该词牌的格式规范,包括句数和字数,可以考查模型对古典词体格律的掌握与实际生成能力。

2.3 评估指标

本文针对负质各类任务的特点,设计并采用了多元化且具有针对性的评估策略,以确保评测结果的科学性与公正性。

多项选择阅读理解 对于多项选择阅读理解任务,本文参考先前的研究^[11]采用准确率(Accuracy)作为主要评估指标。具体做法为:利用正则表达式从大语言模型生成的回复中自动提取答案,若提取失败或提取结果与标准答案不符,则判定该样本为错误。

开放式问答 对于开放式问答任务,评估的目的是判断模型生成的答案是否和标准答案一致。然而由于模型生成答案长度的不确定性和内容的多样

性,自动化评估面临较大的挑战。为此,本文采用 LLM-as-a-Judge 的思路,基于任务特点设计了相应的评估准则,构建了基于大语言模型的自动化评估方案。具体流程为:

(1) 按照各个任务数据比例随机抽取 2 000 个样本,每个样本包含来自不同大模型的预测答案,按照评估准则人工标注大模型答案的二元正确性标签,并给出标注的思考过程。

(2) 如图 1 所示,构建评估微调数据集,每条数据包含评估指令、评估准则、任务输入、标准答案、模型预测答案以及人工标注的思考过程和二元标签。

(3) 使用该数据集微调 Qwen2-7B-Instruct 模型,获得具备评判能力的自动化评估器。

(4) 在另外的 1 000 条数据上检验最终的大语言模型评估器的性能,结果显示与人类评估的一致性达到 89.8%。评估器的具体实现代码和模型权重将与负质基准一同开源。

作为一名阅卷老师,请根据以下评分标准对以下回答进行评价,评价结果的形式是:如果回答正确,输出“Y”,如果回答错误输出“N”。绝对不要输出额外的内容。
评分标准: {criteria}
数据:

问题: {input}\n 预期回答: {reference}\n 回答: {output}
依次提供你对每个标准的解释。结合前面的判断,最后在新的一行上输出“Y”或“N”。
{thinking}
{annotation}

图 1 大语言模型评估器的指令微调提示模板

文本生成 针对文本生成类任务,本文根据任务属性采用差异化评估方案:

(1) 对于以现代汉语为目标的翻译类任务,采用 BLEU 指标^[28],以量化生成文本与参考译文在语义与结构上的相似度。

(2) 对于格式约束生成的对联和填词任务,重点考察模型对对仗和格律等格式规范的遵循情况。

鉴于艺术性评价主观性较强,本文优先关注格式准确率,将韵律、美学层面的评估留待后续研究。具体评测方法为比较模型生成的内容与参考答案的格式是否一致:对联生成仅需比较下联字数是否与上联相同,而词牌填词任务的参考答案来自于词学大师龙榆生著作《唐宋词格律》^[42]中的各个词牌定调,当模型生成的词作的句数和每句字数均与参考答案一致时才被视为格式正确。

上述制定的差异化策略,为评估 LLM 的古汉语文本生成能力提供了客观、可复现的评测方案。

3 实验设置

本文在负质基准上评估了多种代表性的模型,包括开源模型和商业闭源模型。对于开源模型,评估包括 DeepSeek-R1^[43]、Qwen 系列^[44]、GLM-4-9B^[45]、Llama 系列^[46]、InternLM^[47],以及上述模型的衍生体,如 Xunzi^[48]和 ChineseLlama^[49](Llama3.1-8 B-C)。对于闭源模型,本研究评估了 GPT-4o/GPT-4o-mini、GLM-4-plus 和 Qwen-max。这些模型的选择代表了不同的设计理念和技术能力,确保了对负质基准的全面评估。对于以上开源模型,实验使用 VLLM 框架^[50]将模型以半精度部署于英伟达 RTX 3090 显卡上进行推理。对于闭源模型,实验通过调用模型 API 服务,并使用默认参数进行测评。为减少随机性影响,每个任务的结果均为 3 次独立运行的平均值。

在具体实验设置上,本研究采用了零样本设置(Zero-shot),即只向模型提供任务指令和输入,要求模型仅基于预训练知识生成答案。此外,考虑到相关研究中使用的实验范式^[11],本文还采用了少样本上下文提示(5-shot in-context prompting)方法进行评估。这种方法可以通过提供相关示例来帮助模型更好地理解任务要求。

4 结果与分析

本节首先对四类任务分别进行分析,讨论测评结果反映出的模型能力和规律(4.1 节);之后对填词以及任务相关性进行了深入探究(4.2 节);4.3 节讨论大语言模型评估器的测评效果;4.4 节进行错误样例的分析。

4.1 任务类型与模型表现分析

根据负质基准的设计理念,不同类型的任务测评反映了大语言模型不同维度的古汉语能力。

理解型任务 在多项选择阅读理解任务(ACRC、IRC、TCMSRC)上,模型普遍取得了最高的平均分数。如表 3 所示,闭源模型在这类任务上的平均准确率最高达到 86.29%(Qwen-max),而最佳开源模型 Qwen2.5-72B 分数为 85.23%,与闭源模型相当。此类任务性能与模型参数规模呈现明显的正相关性,例如,Qwen2.5 系列模型得分随参数量增加而稳步提升(图 2)。可以推测模型参数越多,其理解和推理能力越强。

表 3 各模型在阅读理解、开放问答和文本生成任务上的零样本评估结果

(单位：%)

模型	ACRC	IRC	TCMSRC	ASQA	LCQA	BA	BD	BCC	PG	PLST	FQST	IST	IPT	PT	CCT	PA	IE	TCMQA	PE
GPT-4o-mini	50.67	77.60	79.23	6.99	10.00	1.04	16.67	78.20	2.00	3.75	16.50	1.25	3.67	5.61	19.77	5.87	1.78	31.93	55.32
GPT-4o	66.33	86.00	84.79	28.57	26.80	10.16	38.98	91.73	41.33	24.00	46.00	12.89	36.33	1.80	19.86	4.88	3.02	38.12	66.07
Qwen-max	86.00	85.90	86.97	52.26	42.40	20.31	40.32	96.61	45.00	58.00	75.00	41.27	73.33	1.64	22.85	6.43	1.85	22.81	53.43
GLM-4-plus	82.33	87.50	83.52	51.36	37.20	29.69	52.96	97.37	76.67	52.25	82.00	49.17	66.00	3.88	17.24	8.53	2.03	23.41	38.82
Deepseek-R1	86.33	88.50	81.97	83.36	82.20	42.71	71.24	97.37	36.67	81.00	96.50	69.23	93.33	0.77	6.95	5.94	1.20	10.95	59.55
InternLM2.5-7B	48.67	77.20	67.85	3.62	4.20	0.00	1.88	68.61	3.00	15.75	31.50	8.52	25.33	2.07	14.08	7.49	0.86	4.32	40.38
Internlm2.5-20B	59.33	80.70	73.95	26.40	31.80	3.39	21.51	93.23	40.67	33.25	70.00	63.20	36.00	1.81	12.51	7.53	0.57	3.78	39.19
GLM4-9B	63.67	77.80	76.05	2.17	5.60	1.30	14.78	73.12	2.67	8.00	28.50	3.64	25.00	9.38	18.06	7.01	1.92	26.36	56.79
Llama3.1-8B	30.00	61.70	56.19	0.36	2.20	0.52	9.14	59.21	0.00	0.25	3.00	0.42	1.00	4.12	9.88	2.53	2.06	39.79	1.09
Llama3.1-8B-C	37.00	67.50	56.01	0.00	0.60	0.00	2.69	72.37	0.33	0.25	2.50	0.10	1.00	7.32	13.72	6.21	1.07	25.29	55.33
Qwen2.0-5B	34.33	46.20	28.05	0.18	0.80	0.26	3.76	12.78	1.00	1.25	2.50	0.83	13.67	4.51	14.51	2.37	2.71	31.14	1.29
Xunzi-Qwen2-7B	45.00	62.30	54.37	12.48	2.20	0.00	5.65	19.55	28.00	5.75	26.00	23.91	11.67	1.06	1.15	3.93	0.20	2.55	22.10
Qwen2-7B	77.00	79.80	82.88	5.24	3.40	1.04	8.87	74.44	0.00	13.00	22.00	2.18	21.67	1.63	15.97	6.75	1.36	27.46	47.84
Qwen2.5-1.5B	46.67	71.70	71.13	2.17	5.40	2.08	17.20	59.77	24.67	11.00	14.50	8.21	30.33	6.91	17.47	2.66	2.61	43.64	1.10
Qwen2.5-3B	57.67	77.60	76.23	18.44	12.80	3.39	18.01	83.83	28.00	18.75	41.00	8.94	41.67	7.78	20.47	6.05	1.45	27.84	61.68
Qwen2.5-7B	71.33	83.20	83.33	22.78	18.60	3.39	20.97	92.67	29.67	28.00	44.50	18.81	41.67	7.64	19.15	6.72	1.74	23.66	55.40
Qwen2.5-14B	78.67	82.50	83.15	34.72	29.60	5.47	38.44	92.67	62.67	38.00	54.00	30.25	57.33	9.28	18.21	6.67	2.35	24.95	62.65
Qwen2.5-72B	83.00	85.80	86.89	35.44	31.60	14.32	43.28	93.80	48.00	46.00	61.00	42.72	77.67	3.46	24.99	7.31	2.46	22.36	41.10




图 2 四类任务中模型性能随参数规模变化的趋势

值得注意的是,不同架构的模型在理解任务上表现差异明显。以古汉语阅读理解任务(ACRC)为例,Qwen系列和GLM系列模型优于Llama系列,尤其在闭源模型对比中,Qwen-max(86.00%)和GLM-4-plus(82.33%)比GPT-4o(66.33%)分别高出19.67和16.00个百分点。这一现象很可能源于中文模型预训练语料中古汉语文本比例更高,使其更能有效捕捉古汉语特有的语言结构与表达特点,从而作出更准确的判断。

开放式问答 在开放式问答任务(表3中ASQA至IPT)上,所有模型性能相较理解型任务显著下降,平均下降40.72个百分点。其中,Deepseek-R1表现最佳(75.36%),远超第二名GLM-4-plus(59.47%)近16个百分点。此类任务考察模型对古汉语知识的记忆和检索能力,参数规模的影响更为显著。如在书籍朝代识别(BD)任务中,Qwen2.5-1.5B(17.20%)到Qwen2.5-72B(43.28%)提升了26.08个百分点;逆向诗词翻译(IPT)任务上的提升最多,达到47.34%(30.33%→77.67%)。

细分来看,溯源类任务(如PLST、FQST、IST)对模型的知识记忆和输出能力要求极高。在这些任务上,参数量多的中文模型展现出显著优势,因为更多的参数可以记忆更多预训练数据中的古汉语领域知识。尤其Deepseek-R1在诗句溯源(PLST, 81.00%)和名言溯源(FQST, 96.50%)两项任务上分别比第二名高出23.00和14.50个百分点,表明其回答前的思考推理(Thinking/Reasoning)机制在古汉语知识记忆与输出方面具备独特优势。通过错误案例分析,我们发现小规模模型在开放问答任务中更易产生严重幻觉,不仅答案正确率低,且常出现完全不相关的内容生成。

文本生成 在以 BLEU 为评分标准的文本生成任务(表 3 中 PT 至 PE)上,模型表现与理解和问答任务存在显著差异。首先,模型规模与性能不再呈现图 2 所示的线性扩展趋势,甚至出现了部分“规模倒置”现象。例如,在诗词翻译(PT)任务上,GLM-4-9B(9.38%)的表现优于所有更大规模的模型;在文言文翻译(CCT)任务上,Qwen2.5-72B(24.99%)虽然表现最佳,但与较小规模的 Qwen2.5-3B(20.47%)BLEU 分数仅相差 4.52。这一现象的出现主要有两个原因:一是 BLEU 指标在评估文言文翻译等存在多种正确表达的任务时自身的局限性;二是文本生成任务可进一步分为翻译类和赏析/解释类两大类,所需能力有所区别。在赏析类任务(如 PA、IE)中,模型需要更多的创造性和文化理解,而非简单的知识提取,因此参数规模带来的边际效益减小。最为重要的是,参数规模更大的模型往往会提供更为详尽的解释,这会导致与相对简洁的参考答案计算 BLEU 分数时结果偏低。

值得注意的是,在中医问答(TCMQA)任务上,Qwen2.5-1.5B 模型(43.64%)表现出色,超过了所有其他模型,包括 Qwen-max(22.81%)和 GPT-4o(38.12%)。出现这一反常现象的原因是该任务的形式与抽取式阅读理解任务类似,而大部分模型会对原文中的答案文本用自己的表达方式加以阐述,同样会导致 BLEU 分数偏低。

格式约束生成 表 4 展示了对联生成(CG)和词牌填词(CiG)两个任务在两种实验设置下的结果。相比词牌填词需遵循复杂的句数和字数规则,对联生成只需匹配单句格式更为简单,因此平均得分高出 31.97 个百分点。Qwen-max 在对联生成上表现最佳(97.40%),而 Xunzi-Qwen2-7B 得分为零,这一鲜明对比表明,使用专业知识微调的领域模型在未保持基础指令理解能力和遵循能力的情况下,反而会在此类有结构化要求的任务上表现更差。模型规模与格式约束生成能力关系呈现显著但非线性特征。Qwen2.5-72B 在词牌填词上得分最高(60.67%),但中小规模模型出现了违反规模效应的现象。特别是 Qwen2.5-7B(46.67%)和 Qwen2.5-3B(32.67%)优于 Qwen2-7B(9.00%)和 Qwen2.5-14B(43.33%),表明模型对格律规则的掌握可能受到训练数据分布和特定优化策略的影响,而非简单地随参数量增加。少样本提示对不同模型的影响方向不一致。对表现原本较差的模型,少样本提示通常带来显著性能提升,如 GLM-4-plus 在对联生成上提升了 16.60 个百

分点(47.20%→63.80%)。但对零样本表现已非常优秀的模型,少样本提示反而可能造成干扰,如 GPT-4o 在对联生成上下降了 6.20 个百分点(89.60%→83.40%)。这表明高性能模型可能已形成了稳定的格式理解能力,而示例提供的额外信息反而干扰了其固有知识应用。

表 4 各模型在格式约束的生成任务上的评估效果

(单位: %)

模型	零样本 (Zero-shot)		少样本 (5-shot)	
	CG	CiG	CG	CiG
GPT-4o-mini	79.00	2.33	71.80	10.00
GPT-4o	89.60	55.33	83.40	53.33
Qwen-max	97.40	39.00	94.60	44.00
GLM-4-plus	47.20	42.00	63.80	55.00
Deepseek-R1	93.60	56.67	85.20	54.67
Internlm2.5-7B	37.80	18.67	61.80	18.67
InternLM2.5-20B	69.60	5.33	45.60	6.67
GLM4-9B	69.20	6.33	59.80	10.00
Llama3.1-8B	8.80	0.33	2.00	0.00
Llama3.1-8B-C	44.80	0.67	9.60	1.00
Qwen2.0-5B	32.60	1.67	8.00	0.33
Xunzi-Qwen2-7B	0.00	0.00	0.00	0.00
Qwen2-7B	69.40	9.00	39.20	10.67
Qwen2.5-1.5B	56.60	20.67	65.80	36.67
Qwen2.5-3B	28.20	32.67	13.00	13.67
Qwen2.5-7B	38.00	46.67	71.00	46.00
Qwen2.5-14B	67.40	43.33	47.40	28.00
Qwen2.5-72B	91.20	60.67	85.80	53.67

表 5 给出了各模型在 4 大类任务上的平均表现。根据负负基准的设计思路,多项选择阅读理解(RC)、开放式问答(QA)、文本生成(TG)和格式约束生成(PG)的四大类任务的难度是递增的,然而从本文中测评的 LLM 的平均表现来看,QA 任务的难度最高。这主要是因为参数量小的模型不足以存储 QA 任务需要的古汉语专业知识,更容易出现幻觉现象。同样,没有学习过专业知识的人也需要查阅书籍才能回答此类任务。这意味着采用检索增强的方案来评估 LLM,可以为衡量大语言模型古汉语能力提供一个全新的视角。

表 5 各模型在各任务类别上的平均表现
(单位：%)

模型	RC	QA	TG	PG
GPT-4o-mini	69.17	13.98	20.05	40.67
GPT-4o	79.04	35.68	22.29	72.47
Qwen-max	86.29	54.45	18.17	68.20
GLM-4-plus	84.45	59.47	15.65	44.60
Deepseek-R1	85.60	75.36	14.23	75.14
InternLM2.5-7B	64.57	16.24	11.53	28.24
Internlm2.5-20B	71.33	41.95	10.90	37.47
GLM4-9B	72.51	16.48	19.92	37.77
Llama3.1-8B	49.30	7.61	9.91	4.57
Llama3.1-8B-C	53.50	7.98	18.16	22.74
Qwen2.0-5B	36.19	3.70	9.42	17.14
Xunzi-Qwen2-7B	53.89	13.52	5.17	0.00
Qwen2-7B	79.89	15.18	16.84	39.20
Qwen2.5-1.5B	63.17	17.53	12.40	38.64
Qwen2.5-3B	70.50	27.48	20.88	30.44
Qwen2.5-7B	79.29	32.11	19.05	42.34
Qwen2.5-14B	81.44	44.32	20.69	55.37
Qwen2.5-72B	85.23	49.38	17.00	75.94
Average	70.30	29.58	15.68	40.61

4.2 词牌填词与任务相关性分析

词牌填词作为负质基准中最具挑战性的任务，能够反映大语言模型记忆、理解并应用词牌格律的古汉语写作能力。图 3 展示了各模型在 30 种常见词牌上格式准确率的热力图，横轴模型按平均分数降序排序，纵轴词牌名按照其标准形式的字数升序排序。从图中可以看出，左侧偏下区域颜色较深，而右侧和左上区域颜色较浅。这说明填词任务的难度与词牌的字数有关，词牌字数越多越复杂，模型越难生成结构正确的词作。同时，不同的模型之间能力差距显著，强大的模型如 Qwen2.5-72B 和 Deepseek-R1 在几乎所有词牌上均有得分，而较弱的模型如 Llama 和 Xunzi-Qwen2-7B 在所有词牌上均得分为 0。但模型能力的差距虽然与参数量相关但并不绝对，如 Qwen2.5-7B 和 InternLM-2.5-20B，说明模型填词能力可能与训练数据和训练策略有关。然而热力图中存在一些分数异常的词牌，如浪淘沙、南乡子、虞美

人、临江仙等，几乎所有模型在这几个词牌上的分数都较低。通过对具体的生成结果进行分析，可以发现这些偏低的分数是由于模型生成了不同于测评标准形式的词牌变体，这可能与大模型预训练语料中各个词牌对应的变体作品的比例有关。同样，这个现象也说明词牌填词任务仍有更大的开发测评与研究空间，未来负质基准计划通过设置不同的 prompt 增加对词牌变体的测评，并逐步完善对词牌韵律和意境的评估方案。

负质基准中有多个任务涉及诗词，如诗词创作、诗句溯源、逆向诗词翻译、诗词翻译、诗词赏析等，直觉上这些任务的性能应该与词牌创作任务具有相关性。然而，在计算了各个任务分数之间的皮尔森相关系数后，得分与词牌填词最相关的五个任务分别是逆向诗词翻译(0.86)、书籍朝代(0.82)、诗句溯源(0.79)、古汉语阅读理解(0.77)和歇后语问答(0.76)。而诗词创作、诗词翻译、诗词赏析的相关性分数分别为 0.72、-0.08 和 0.36，在所有任务中的排名分别为 8、20 和 18。出现这个现象的原因是诗词翻译/赏析任务要求模型从古汉语生成现代汉语，这与词牌填词和逆向诗词翻译的过程正好相反，可见古汉语生成能力是区别于现代汉语表达能力的独特技能，对大语言模型提出了更高的专业化要求。

4.3 大语言模型评估器验证

为确保开放式生成任务评估的科学性与可靠性，本节对基于大语言模型的自动评估器进行了系统验证。我们从 GPT-4o 在各类任务中的生成结果随机抽取 1 000 个样本，由三位古汉语领域专家独立评判并协商一致，形成高质量人工标注数据。以此为正确评估基准，计算自动评估器的多种一致性评估指标，结果如图 4 和表 6 所示。

表 6 自动评估器评测与人工标注的一致性指标

指标	得分	不计入 PG 任务
一致性	0.898	0.930
Cochan's κ	0.764	0.830
精确率	0.833	0.815
召回率	0.843	0.951
F ₁ 值	0.838	0.878
皮尔逊相关子数	0.764	0.835




图3 各模型在30种常见词牌上的表现热力图




图4 不同任务上一致性分数对比

验证结果表明,自动评估器与人工评判的结果一致性达 89.8%,计算 Cohen's κ 分数为 0.764,说明两者显著一致。进一步分析发现,评估一致性在不同任务类型上存在显著差异:①事实类任务一致性最高:书籍朝代识别(BD, $\kappa=0.950$)和诗句溯源(PLST, $\kappa=0.905$)等具有明确答案的任务,自动评估器与人工标注几乎完全一致。这类任务答案客观

明确,评判标准清晰,自动评估器表现出色。②主观性任务一致性较低:歇后语问答(ASQA, $\kappa=0.567$)等具有多种可接受答案的任务,评估一致性显著下降。这与人工评估者之间也存在分歧的现象一致,反映了任务本身的主观性特点。③特殊案例处理局限:诗歌生成(PG)任务的评估一致性最低。深入分析发现,当模型同时生成多种体裁(如五言诗、七

言诗和词)时,自动评估器过于僵化地将其全部判定为错误,而人工评估则更灵活地考虑了多种体裁内容的正确性。如表 6 所示,不计入 PG 任务时,整体 Cochen’s κ 提升至 0.930。④宽严标准差异:从精确率(0.815)低于召回率(0.951)的现象可见,自动评估器在除 PG 外的任务上标准略宽松,即倾向于接受人工评估者判定为错误的答案。这一现象提示我们在优化自动评估器时需加强边界案例的识别能力。

尽管存在上述局限,多项指标均表明,本研究的自动评估体系能够在保证科学性的同时显著提高评

测效率。未来改进方向主要包括:增强对复杂回答的灵活处理能力、细化评估逻辑以适应不同任务特点,扩充高质量标注数据以提高边界案例处理能力。

4.4 典型错误案例分析

通过对不同任务中的错误案例分析,我们可以深入了解模型在古汉语处理时的典型困难。表 7 展示了逆向诗词翻译任务中的代表性案例,该任务要求模型根据现代汉语释义还原原始古诗词,对模型的古汉语知识和推理能力提出了严格挑战。

表 7 关于逆向诗词翻译任务的样例分析

任务/模型	参考答案/模型输出
逆向诗词翻译	根据以下翻译给出对应的古诗词原文。在这个地方荆轲告别燕太子丹,壮士悲歌壮气,怒发冲冠。那时的人已经都不在了,今天的易水还是那样的寒冷
GPT-4o-mini (错误)	根据你提供的翻译内容,原文对应的古诗词是《易水送别》。这首诗的作者是屈原,诗中描绘了荆轲在易水边告别燕太子丹的情景,以及壮士的坚定与悲壮。诗的最后一句表现了时光的流逝和易水依旧的寒冷氛围
GPT-4o (错误)	这段翻译对应的古诗词原文是唐代骆宾王所作的《易水送别》,原文如下:《易水送别》作者:骆宾王 此地别燕丹,壮士发冲冠。昔人已乘黄鹤去,此地空余易水寒
Qwen-max (正确)	这首诗的原文是唐代诗人骆宾王的《于易水送人》: 此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒
GLM-4-plus (正确)	根据您提供的翻译,这段描述对应的是荆轲刺秦王的故事,其中特别提到了荆轲与燕太子丹告别的场景,以及易水的寒冷。这让人联想到唐代诗人骆宾王的《于易水送人》:此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒。这首诗正是描绘了荆轲在易水边告别燕太子丹的情景,以及诗人对那段历史的感慨。诗中的"壮士发冲冠"与您翻译中的"壮士悲歌壮气,怒发冲冠"情感相符,而"今日水犹寒"则对应了"今天的易水还是那样的寒冷"
Deepseek-R1 (正确)	<think>好的,我需要根据用户提供的翻译找出对应的古诗词原文。首先,用户给的翻译是关于荆轲告别燕太子丹的场景,提到了壮士的悲歌、怒发冲冠,以及现在人已不在,易水依然寒冷。首先,我想到荆轲刺秦王的故事,相关的诗歌可能涉及易水送别。骆宾王的《于易水送人》可能符合,其中"此地别燕丹,壮士发冲冠"这两句和用户的第一句翻译对应。接下来的"昔时人已没,今日水犹寒"正好对应翻译的后两句。确认一下这首诗的全文是否正确,骆宾王的这首五绝确实描述了在易水送别的情景,前两句讲荆轲的故事,后两句表达对往昔英雄的怀念和环境的依旧寒冷。所以应该就是这首诗了。可能需要进一步检查是否有其他诗人的作品也涉及相同主题,但考虑到骆宾王的这首诗较为著名且内容匹配度高,应该是正确的答案。</think> 对应的古诗词原文是骆宾王的《于易水送人》:此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒。注:这首五言绝句通过"发冲冠"的细节描写和"水犹寒"的自然感受,既再现了《史记·刺客列传》中"风萧萧兮易水寒,壮士一去兮不复还"的悲壮场景,又暗含了诗人对现实境遇的深沉感慨。"
InternLM2.5-7B (正确)	此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒
InternLM2.5-20B (错误)	您所引述的内容描述的是历史上著名的荆轲刺秦王这一悲壮的事件,这段话激昂而深情,表达了对过去英雄人物的怀念与敬仰,很可能是当代人根据古文文意创作的仿古诗词或现代作品,并不是直接取自某个具体的古诗词原文。它借鉴了古文的表达风格,带有浓厚的历史感和情感色彩。虽然它的语言是现代的,但是风格上有古风的韵味。 从这段文字的主题和意象来看,它可能与以下两句古文有相似之感: 1.《史记·刺客列传》中荆轲行刺秦王前的告别场景。 2. 唐代诗人高适的诗句"此地别燕丹,壮士发冲冠",这一句诗表达了历史上的荆轲告别燕太子丹时的英雄悲壮。不过,这两处都不完全匹配您给出的那一段,后者带有鲜明的现代汉语表达习惯,所以虽然有联系,并非直接引用,而是融会贯通。 根据您提供的文句,没有确切的古代诗词原文与之完全对应,您提供的文句更像是荆轲刺秦这一历史事件的现代文创作或者概括性描述,没有直接对应的诗句。若要查找相近的古代诗歌,可能需要更多信息才能在古典文学中找到相匹配的文献。如果您是要创作相关的诗歌或文章,不妨继续遵循这种以史入诗的创作风格,并依据《史记》等史书中的记载来创作。 如果您有完整或更详尽的原诗句上下文,我可以帮您查找更准确的原文。若没有,则这段话可能不属于直接引用的古诗词,而是对该历史事件的一种现代文表述

续表

任务/模型	参考答案/模型输出
Llama3.1-8B (错误)	原文：原句可能出自韩非子或出自史记,或者还有其他相关的文献中的一些传说。这句较为流行的版本出自李膺注释的《韩非子》或是作为《史记》中的一个注释。“乘此易水而南下见匈奴…”(“乘” 匀音入“阴”),后面为“浪填咽,捐覆寒”,这是称之为易水悲歌。 但最为人所知的版本是标注在宣宗李纲的编写的《宣宗本草》中的有关写作中最为普遍,读作「大风泪殷冒,牛角夏尽火.由此可以看出,当初送别时丘允の頸文(to be a 的送别文)(省略……)
Llama3.1-8B-C (错误)	这段描述摘自司马迁的历史著作《史记·刺客列传》中的荆轲刺秦王篇。原文如下：“荆轲别燕太子,壮士悲歌壮气,怒发冲冠。” 这里没有直接描述易水的寒冷,原文中的有关易水的描述在后文中提到,具体如下:“既而还赵,至易水,悼王如不见。至日暮,发。” 根据您的描述,后半句似乎有些误解或者自行补充的内容,原文中并没有“那时的人已经都不在了,今天的易水还是那样的寒冷”这样的表述。在历史记载中,荆轲在易水与秦军遭遇时,因燕太子丹发病未能出行,故未能成行刺秦王的任务,而由如与越王辅佐刺杀秦王的行动最终以失败告终
Xunzi-Qwen2-7B (错误)	回答:荆轲歌送燕太子,壮士歌高燕逆龙;易水寒今已难渡,燕太子丹不复存。求得青萍与干将,岂能长为天下来安。壮士悲歌亦有泪,慷慨悲歌岂任颜。(省略……)易水会无间,长风既遥听。本来已谁用,念此书长亭。今夕思几何,明月何当流
Qwen2-7B (错误)	古诗词原文:《荆轲歌》 风萧萧兮易水寒,壮士一去兮不复还。 译文:在这个地方荆轲告别燕太子丹,壮士悲歌壮气,怒发冲冠。 那时的人已经都不在了,今天的易水还是那样的寒冷
Qwen2.5-1.5B (错误)	今天易水已无冰,只照见风中一段哀歌声
Qwen2.5-14B (正确)	根据您的翻译内容,对应的古诗词原文是王昌龄的《易水送别》: 此地别燕丹,壮士发冲冠。 昔时人已没,今日水犹寒
Qwen2.5-72B (正确)	这首诗的原文是:《易水歌》【唐】骆宾王 此地别燕丹,壮士发冲冠。昔时人已没,今日水犹寒

以骆宾王《于易水送人》为例,我们可归纳出四类典型错误模式:①知识性错误(内在幻觉):如 GPT-4o-mini 错误地将《于易水送人》归为屈原所作,显示其基础古典文学知识的缺失。这种错误在参数较少或训练数据中古汉语比例较低的模型中更为常见。②内容混淆(外在幻觉):如 GPT-4o 将原诗第三、四句错误地编造为“昔人已乘黄鹤去,此地空余易水寒”,将两首不同的诗内容混淆在一起。这表明模型虽有相关知识,但在整合输出时产生了错误^[51]。这种错误即使在顶级闭源模型中也时有发生,说明古汉语知识的精确检索与输出仍十分具有挑战性。③过度推理:如 InternLM2.5-20bB 比其 7B 版本展示了更复杂的推理过程,包括分析多个潜在的诗歌出处,但最终导致错误结果。参数量增加带来的推理能力提升有时反而会引入不必要的复杂性,尤其在答案相对简单直接的情况下。但值得指出的是,参数规模更大的 Deepseek-R1 在推理过程中表现出了更强的鲁棒性,这与其独特的后训练策略^[43]是分不开的。④任务理解错误:如 Xunzi-Qwen2-7B 和 Qwen2.5-1.5B 未能理解“还原原诗”

的任务要求,而是进行了创作或续写。这类错误反映了模型在指令理解能力方面的不足,可能与模型训练过程中缺少类似逆向翻译任务有关。

表现优异的模型如 Deepseek-R1、Qwen-max 和 GLM-4-plus 能够准确识别原诗并提供正确的作者和篇名信息,表明它们不仅掌握了丰富的古汉语知识,还能准确理解任务要求并精确输出相关信息。这类模型通常参数规模更大或在训练过程中接触了更多高质量的古汉语文本。案例分析进一步证实了我们之前的观察:古汉语处理能力与模型参数规模密切相关,但数据和后训练策略同样至关重要。专业领域知识的获取不仅依赖于模型容量,还与特定领域数据在预训练语料中的比例有关。

5 结论

本文提出了负质,一个面向古汉语文本理解能力与生成能力的大语言模型测评基准。通过对当前主流模型在 21 项多样化任务上的系统评估,本文揭示了以下重要结论:

主要发现 ①尽管现代大语言模型在理解型任务上表现优异,但在需要专业知识和深层文化理解运用的生成任务上仍面临显著挑战;②在古汉语文本生成任务中,模型在保持低幻觉和遵循严格格式规范方面表现严重不足;③模型规模和架构选择对性能有显著影响,参数规模更大、针对中文语料专门训练的模型如 Deepseek-R1、Qwen-max 和 GLM-4-plus 在多项古汉语相关任务上展现出明显优势;④特别地,Deepseek-R1 在开放式问答任务上的表现远超其他模型(75.36%),表明其独特的后训练策略对古汉语知识推理能力和生成能力有显著提升。

技术贡献 ①建立了涵盖理解与生成能力的标准化评测框架,填补了古汉语生成任务评测的空白;②针对古汉语生成任务的特殊性,提出了混合评估方法,结合规则约束与大模型自动评测,提升了评估效率与一致性;③系统评估了 18 种主流模型,为古汉语处理技术发展提供了全面的性能基线和改进方向。

局限性与挑战 尽管负质基准在多个方面取得了进展,但仍存在以下局限性:①评估指标局限:BLEU 等传统指标和本文提出的大模型评估器难以全面反映古汉语文本的文化内涵和艺术价值,未来需要开发更适合古汉语特点的评估指标;②文化背景复杂性:古汉语涉及丰富的历史文化背景,当前评估主要关注语言形式,对文化适应性的考察有待加强;③任务覆盖面:虽然涵盖了 21 项任务,但古汉语领域博大精深,在古代文学、词汇语义、音韵学等专业领域的评测任务仍需进一步扩展。

未来工作方向 ①开发更加精细化的古汉语生成质量评估方案,结合韵律、对仗、意境等多维度考量;②扩展基准任务类型,增加文学创作、古汉语语音、语义演变,跨朝代文本理解以及词牌变调生成等任务;③补充如检索增强的生成设置下的测评实验,并与人类水平进行对比;④探索基准在古汉语教学、文化传承等实际应用场景中的价值和改进方向。

负质基准的发布不仅为古汉语文本处理技术的发展提供了重要的评测工具,也为人工智能在文化遗产保护和传承领域的应用提供了重要支撑和借鉴。我们期待该基准能够推动古汉语处理技术的进步,为中华优秀传统文化的数字化传承贡献力量。

参考文献

- [1] HOLCOMBE C. Rethinking early east Asian history [J]. Education About Asia, 2006, 11(2): 9-13.
- [2] ZHOU B. A comprehensive review of Japanese Chinese biographical history books[J]. Journal of Historiography,

- 2009(3): 98-104.
- [3] 詹卫东,郭锐,常宝宝,等. 北京大学 CCL 语料库的研制[J]. 语料库语言学, 2019, 6(1): 71-86.
- [4] 荀恩东,饶高琦,肖晓悦,等. 大数据背景下 BCC 语料库的研制[J]. 语料库语言学, 2016, 3(1): 93-109.
- [5] 胡初奋,李绅,诸雨辰. 基于深层语言模型的古汉语知识表示及自动断句研究[J]. 中文信息学报, 2021, 35(4): 8-15.
- [6] 劳斌,彭瑶,吕薇,等.古汉语 NLP 研究现状综述(2009—2024)[J].现代信息科技,2024,8(13): 146-150,155.
- [7] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[EB/OL]. [2024-06-01] https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [8] JI Z, SHEN Y, SUN Y, et al. C-CLUE: A benchmark of classical Chinese based on a crowdsourcing system for knowledge graph construction [C]//Proceedings of the Knowledge Graph and Semantic Computing: Knowledge Graph Empowers New Infrastructure Construction. Singapore: Springer, 2021: 295-301.
- [9] ZHOU B, CHEN Q, WANG T, et al. WYWEB: A NLP evaluation benchmark for classical Chinese [C]//Proceedings of the Association for Computational Linguistics: ACL 2023. Toronto, Canada: Association for Computational Linguistics, 2023: 3294-3319.
- [10] ZHANG Y, LI H. Can large language model comprehend ancient Chinese?: A preliminary test on ACLUE[C]//Proceedings of the Ancient Language Processing Workshop. Varna, Bulgaria: INCOMA Ltd., Shoumen, Bulgaria, 2023: 80-87.
- [11] WEI Y, XU Y, WEI X, et al. AC-EVAL: Evaluating ancient Chinese language understanding in large language models [C]//Proceedings of the Association for Computational Linguistics: EMNLP 2024. Miami, Florida, USA: Association for Computational Linguistics, 2024: 1600-1617.
- [12] BACHMAN L F. Fundamental considerations in language testing[M]. Berlin OUP Oxford, 1990.
- [13] ZENG H. Measuring massive multitask Chinese understanding[J/OL]. arXiv preprint arXiv: 2304.12986, 2023.
- [14] HUANG Y, BAI Y, ZHU Z, et al. C-Eval: A multi-level multi-discipline Chinese evaluation suite for foundation models [C]//Proceedings of the 37th International Conference on Neural Information Processing Systems, 2023, 36: 62991-63010.
- [15] LI H, ZHANG Y, KOTO F, et al. CMMLU: Measuring massive multitask language understanding in chinese[J/OL]. arXiv preprint arXiv: 2306.09212, 2024.
- [16] XU L, LI A, ZHU L, et al. SuperCLUE: A comprehensive Chinese large language model benchmark [J]. arXiv preprint arXiv: 2307.15020, 2023.
- [17] SU Q, WANG Y, DENG Z, et al. Overview of

- CCL23-eval task 1: Named entity recognition in ancient Chinese books[C]//Proceedings of the 22nd Chinese National Conference on Computational Linguistics. Harbin, China: Chinese Information Processing Society of China, 2023: 34-40.
- [18] LI B, CHANG B, LIU R, et al. Overview of EvaHan2025: The first international evaluation on ancient Chinese named entity recognition [C]//Proceedings of the 2nd Workshop on Ancient Language Processing. The Albuquerque Convention Center, Laguna: Association for Computational Linguistics, 2025: 156-164.
- [19] LYN4EVER29, GuwenEE: A corpus for event extraction in classical chinese [EB/OL]. [2024-06-23]. <https://github.com-/Lyn4ever29/GuwenEE>.
- [20] YUTONG L, BIN W, TING B. The construction and analysis of classical Chinese poetry knowledge graph [J]. Journal of Computer Research and Development, 2020, 57(6): 1252-1268.
- [21] SHAO Y, SHAO T, WANG M, et al. A sentiment and style controllable approach for chinese poetry generation[C]//Proceedings of the CIKM '21: The 30th ACM international Conference on Information and Knowledge Management, Virtual Event, Queensland, Australia, 2021: 4784-4788.
- [22] GUO G, YANG J, LU F, et al. Towards effective ancient Chinese translation: Dataset, model, and evaluation[C]//Proceedings of the Natural Language Processing and Chinese Computing. Cham: Springer Nature Switzerland, 2023: 416-427.
- [23] WANG D, LIN L, ZHAO Z, et al. EvaHan2023: Overview of the first international Ancient Chinese translation bakeoff [C]//Proceedings of ALT: Ancient Language Translation Workshop. Macau SAR, China: Asia-Pacific Association for Machine Translation, 2023: 1-14.
- [24] HU D, SUN G, LIU L, et al. Evaluation of ancient Chinese natural language understanding in large language models based on ACHNLU [C]//Proceedings of the Wisdom, Well-being, Win-win. Cham: Springer Nature Switzerland, 2024: 3-18.
- [25] LI H, ZHU J, CAO S, et al. Poetic expression through scenery: Sentimental Chinese classical poetry generation from images[C]//Proceedings of the Database Systems for Advanced Applications. Cham: Springer International Publishing, 2021: 629-637.
- [26] MA J, ZHAN R, WONG D F, et al. Human-in-loop classical Chinese poetry generation system [C]//Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations. Dubrovnik, Croatia: Association for Computational Linguistics, 2023: 57-66.
- [27] YU C, ZANG L, WANG J, et al. CharPoet: A Chinese classical poetry generation system based on token-free LLM[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Bangkok, Thailand: Association for Computational Linguistics, 2024: 315-325.
- [28] PAPINENI K, ROUKOS S, WARD T, et al. BLEU: A method for automatic evaluation of machine translation [C]//Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, 2002: 311-318.
- [29] LIN C Y. ROUGE: A package for automatic evaluation of summaries [C]//Proceedings of the Text Summarization Branches Out, 2004: 74-81.
- [30] BANERJEE S, LAVIE A. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments [C]//Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or summarization, 2005: 65-72.
- [31] WEI H, HE S, XIA T, et al. Systematic evaluation of LLM-as-a-judge in LLM alignment tasks: Explainable metrics and diverse prompt templates [J/OL]. ArXiv preprint arXiv: 2408.13006, 2024.
- [32] BACHMAN L F, PALMER A S. Language testing in practice: Designing and developing useful language tests[M]. Berlin OUP Oxford, 1996.
- [33] REN M, HUANG H, ZHOU Y, et al. TCM-SD: A benchmark for probing syndrome differentiation via natural language processing[C]//Proceedings of the 21st Chinese National Conference on Computational Linguistics. Nanchang, China: Chinese Information Processing Society of China, 2022: 908-920.
- [34] WANG Z, ZHANG S, ZHANG X, et al. 古汉语通假字资源库的构建及应用研究 (the Construction and Application of an Ancient Chinese Language Resource on Tongjiazi) [C]//Proceedings of the 22nd Chinese National Conference on Computational Linguistics. Harbin, China: Chinese Information Processing Society of China, 2023: 535-546.
- [35] PWXCOO. 中华新华字典数据库. 包含歇后语、成语、词语、汉字[EB/OL]. [2024-04-13]. <https://github.com/pwxcoo/Chinese-xinhua>.
- [36] CHOW G. daizhigev20: 殆知阁古代文献[EB/OL]. [2024-04-13]. <https://github.com/daizhigev20/daizhigev20>.
- [37] 古诗文网. 古诗文经典传承[EB/OL]. [2024-04-13]. <https://www.gushiwen.cn/>.
- [38] REN Z, REN Y, LI Z, et al. TCMM: A unified database for traditional Chinese medicine modernization and therapeutic innovations [J]. Computational and Structural Biotechnology Journal, 2024, 23: 1619-1630.
- [39] TIANCHI. 中医文献问题生成数据集[EB/OL]. [2024-04-13]. <https://tianchi.aliyun.com/dataset/86895>.

- [40] WB14123. Couplet dataset[EB/OL]. [2024-04-13]. <https://git-hub.com/wb14123/couplet-dataset>.
- [41] 苏州图谱信息技术有限公司. 古籍文献知识图谱网[EB/OL]. [2024-05-03]. <https://cnkgraph.com/CiTune>.
- [42] 龙榆生. 唐宋词格律[M]. 上海：上海古籍出版社，2010.
- [43] DEEPSEEK-AI, GUO D, YANG D, et al. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning [J/OL]. arXiv preprint arXiv: 2501.12948, 2025.
- [44] QWEN, YANG A, YANG B, et al. Qwen 2.5 technical report[J/OL]. arXiv preprint arXiv: 2412.15115, 2024.
- [45] GLM T, ZENG A, XU B, et al. ChatGLM: A family of large language models from GLM-130B to GLM-4 all tools[J/OL]. arXiv preprint arXiv: 2406.12793, 2024.
- [46] GRATTAFIORI A, DUBEY A, JAUHRI Z, et al. The Llama 3 herd of models[J/OL]. arXiv preprint arXiv: 2407.21783, 2024.
- [47] CAI Z, CAO M, CHEN H, et al. InternLM2 technical report[J/OL]. arXiv preprint arXiv: 2403.17297, 2024.
- [48] XUNZI-LLM-OF-CHINESE-CLASSICS. Xunzi-LLM-of-Chinese-Classics[EB/OL]. [2024-04-13]. <https://github.com/X-unzi-LLM-of-Chinese-classics/XunziALLM>.
- [49] LLAMAFAMILY. Llama-chinese[EB/OL]. [2024-05-03]. <https://github.com/LlamaFamily/Llama-Chinese>.
- [50] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with paged attention[C]//Proceedings of the 29th Symposium on Operating Systems Principles. New York, NY, USA: Association for Computing Machinery, 2023: 611-626.
- [51] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.



赵尚卿(1998—), 博士, 主要研究领域为大语言模型与知识图谱。
E-mail: sqzhao@stu.ecnu.edu.cn



柏晓鹏(1981—), 博士, 副教授, 主要研究领域为计算语言学、词汇学、大语言模型与中文教育。
E-mail: xpbai@zhwx.ecnu.edu.cn



兰曼(1974—), 通信作者, 博士, 教授, 主要研究领域为自然语言处理、人工智能与教育科技。
E-mail: mlan@cs.ecnu.edu.cn